Cómo está constituida la base

La unidad de análisis es el hogar. Pobre, la variable que se predice, también es del hogar: 1 si el hogar es pobre y 0 si no lo es. En la base de entrenamiento esos valores se guardan como Yes y No.

Train: 164,960 hogares y 543,109 personas.
Test: 66,168 hogares y 219,644 personas. El test no trae Pobre.
Pobres en train: 33,024 (20.02%). No pobres: 131,936.
Valores faltantes después de la limpieza: 0.
Personas y hogares cuadran: la suma de Nper es igual al número de filas de personas.

Las personas no entran al modelo como filas. Cada persona se resume dentro de su hogar (edad, educación, ocupación, horas, cotización) y esa fila se une al hogar por id. Quedan fuera de la unidad de gasto el servicio doméstico, los pensionistas y los trabajadores que no comparten el presupuesto. El arriendo, la ciudad, la tenencia y el número de cuartos vienen de la base de hogares.

No hay variables de ingreso. Esas preguntas no están en el test, así que no sirven para armar el archivo que se sube a Kaggle.

Bogotá tiene 10,567 hogares en train (6.4%) y 0 en test. La pobreza en Bogotá es 9.8% y en el resto del train 20.7%.

La clase está desbalanceada

Uno de cada cinco hogares de train es pobre (20.02%).

Un clasificador que dijera que nadie es pobre acertaría el
79.98% de los hogares y tendría F1 igual a 0.
El acierto sale alto porque la clase mayoritaria es no ser pobre.
No mide si el modelo encuentra a los hogares pobres. La métrica de
la competencia es el F1, que cae a cero si no hay ningún acierto
sobre la clase pobre.

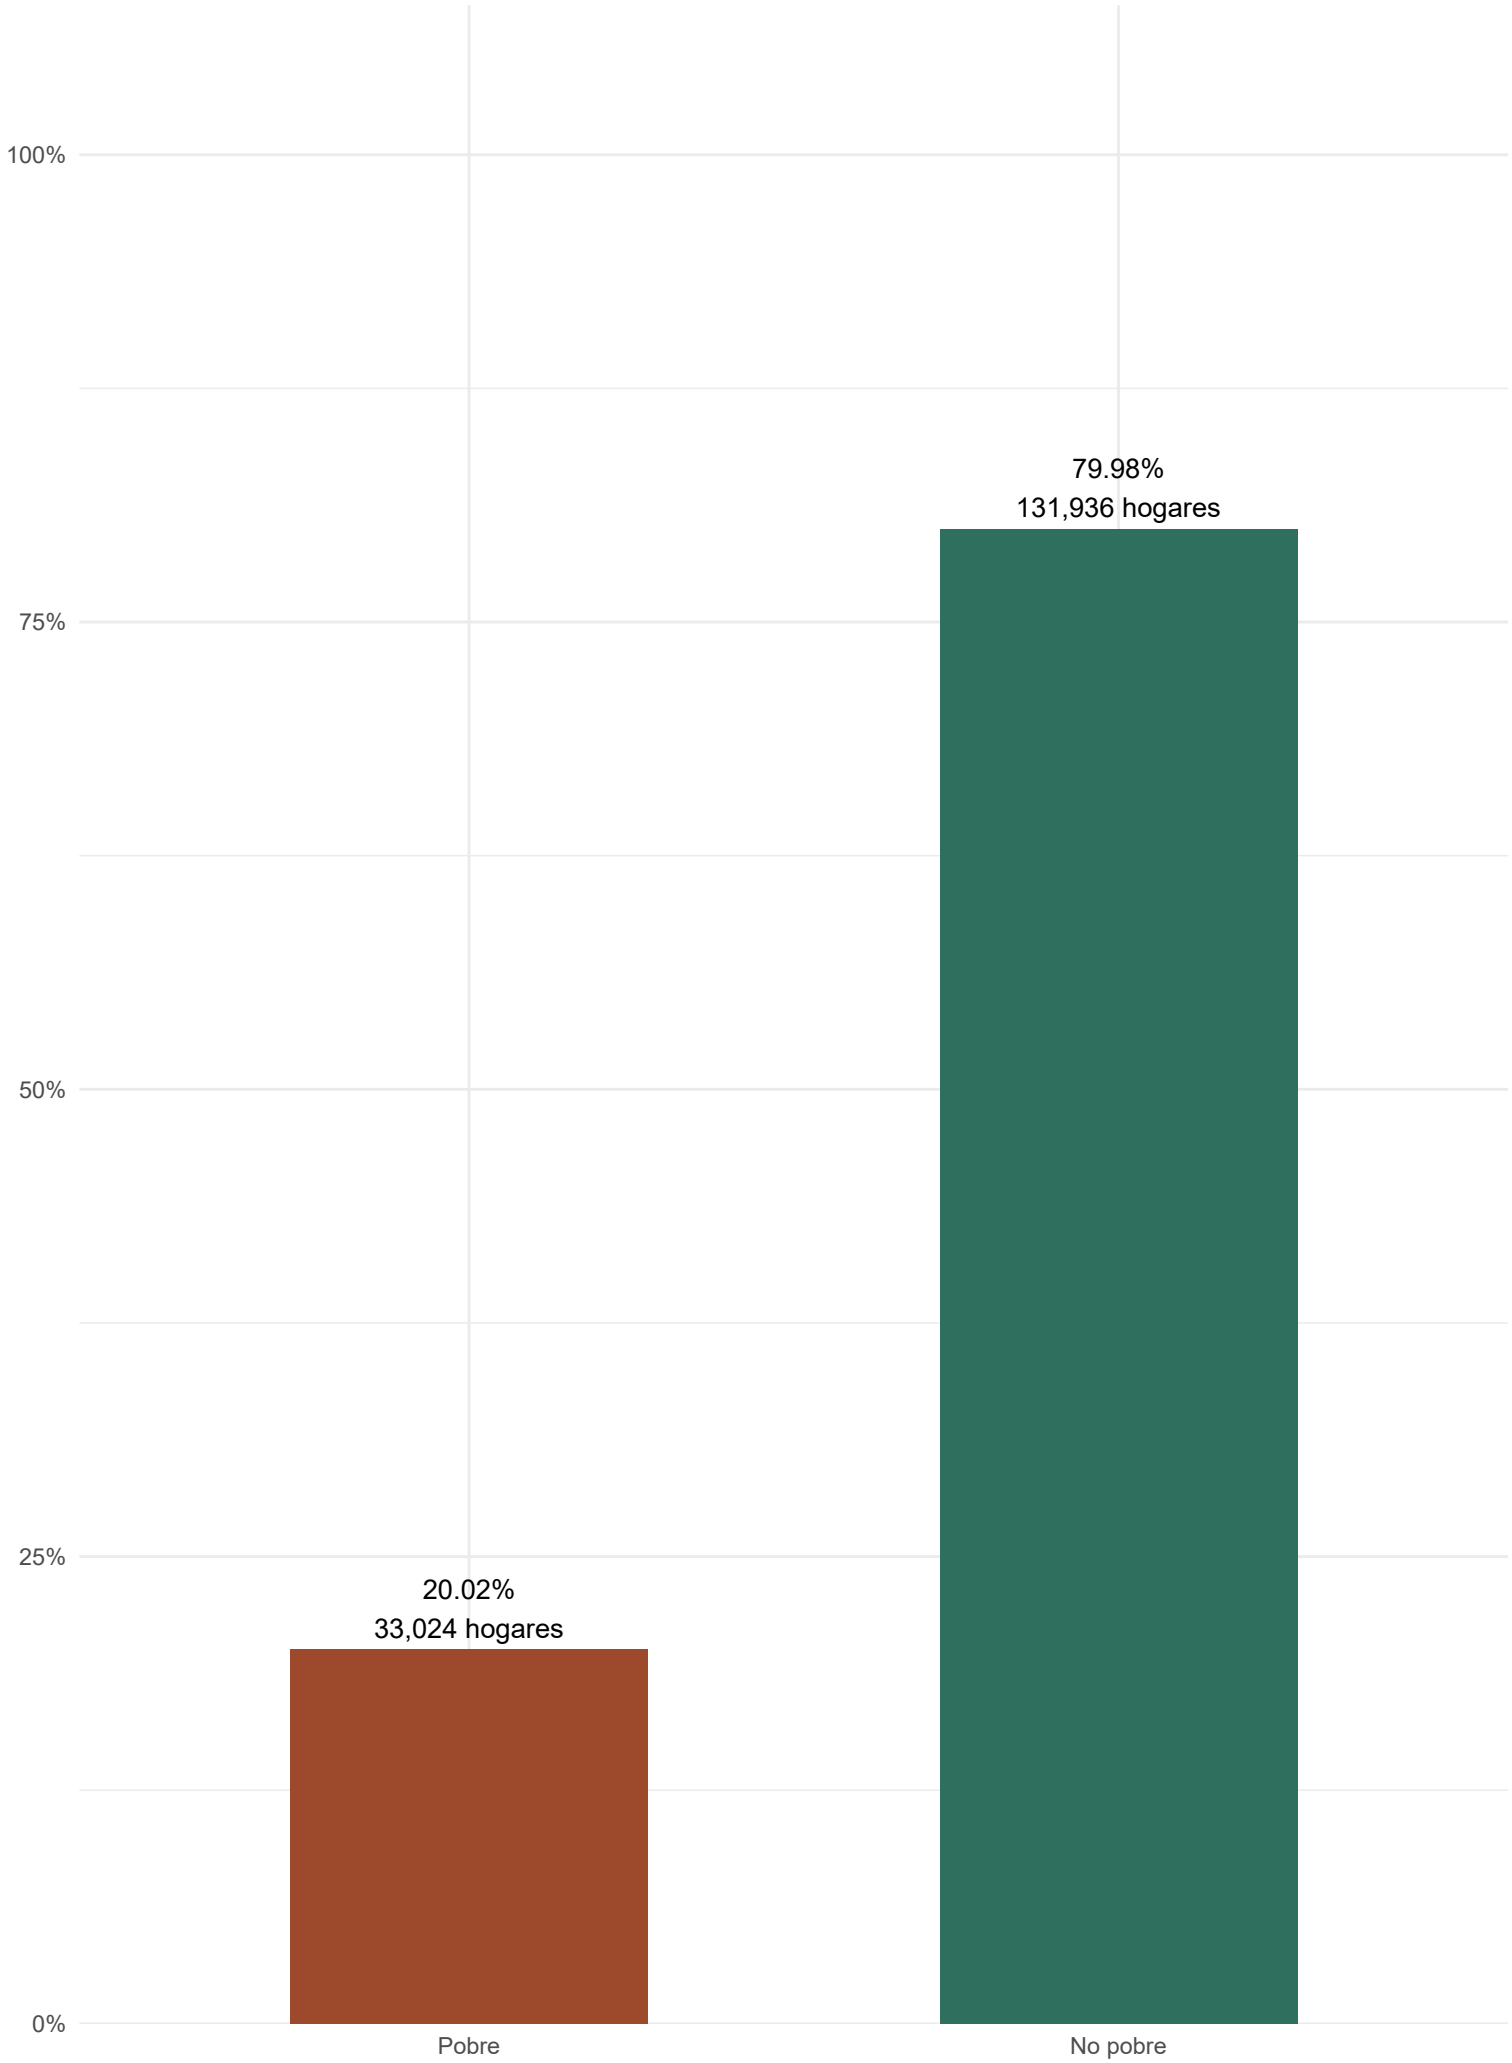
Por eso el punto de corte de los modelos no se deja en 0,5. Se elige
el umbral que maximiza el F1 en hogares que el modelo no usó para
entrenar ese fold. Esas predicciones conservan el 20% de pobres.

Repetir cuatro veces a los hogares pobres es solo un recurso de
entrenamiento, dentro de cada fold. No cambia esta distribución.
La validación y el test siguen con la proporción real de la muestra.

Bogotá, que no está en el test, tiene una pobreza de 9.8%, frente a 20.7% en el resto
del train. Entrenar con Bogotá cambia un poco
la mezcla de hogares que el modelo ve, respecto del test.

Distribución de la pobreza en train

Cada barra es la proporción de hogares. El test no tiene esta etiqueta.



De 43 variables a las columnas del Random Forest

Los factores sueltan la primera categoría. Las otras 37 variables entran como una columna cada una. Total: 93 columnas. En cada corte el árbol sortea 31.

Factor	Niveles	Categoría que no entra	Columnas
cat_ubicacion	25	ARMENIA	24
cat_tenencia	6	Propia pagada	5
cat_maxEduc	6	Ninguno	5
cat_pos_jefe	9	No ocupado	8
cat_educ_jefe	6	Ninguno	5
cat_tam_empresa_jefe	10	No ocupado	9

Predictores de los cuatro primeros bloques

Vivienda, demografía, empleo y formalidad. Una fila de esta tabla es una columna de la base de hogares.

Variable	Bloque	Tipo	Definición
cat_ubicacion	Vivienda	Factor	Dominio: 23 ciudades, resto urbano y rural
cat_tenencia	Vivienda	Factor	P5090. Seis formas de tenencia de la vivienda
num_personas_cuarto	Vivienda	Razón	Personas del hogar (Nper) / cuartos (P5000)
num_personas_ug	Vivienda	Conteo	Miembros que comparten el presupuesto
num_minors	Vivienda	Conteo	Personas con menos de 18 años
bin_head_male	Demografía	Indicador	1 si el jefe del hogar es hombre
num_old	Demografía	Conteo	Personas mayores de 65 años
num_edad_trabajar	Demografía	Conteo	Personas de 18 a 65 años
prop_dependencia	Demografía	Razón	(Menores + mayores de 65) / personas de 18 a 65
cat_maxEduc	Demografía	Factor	Máximo nivel educativo del hogar
num_educ_jefe_conyuge	Demografía	Promedio	Código educativo 1 a 6 del jefe y del cónyuge
num_ocupados	Empleo	Conteo	Ocupados en la unidad de gasto
prop_ocupados	Empleo	Razón	Ocupados / personas de la unidad de gasto
num_inactivos	Empleo	Conteo	Inactivos que tienen de 18 a 65 años
prop_inactividad	Empleo	Razón	Inactivos / personas de 18 a 65
num_cotizantes	Formalidad	Conteo	Cotizan a pensión (P6920) en la unidad de gasto
bin_hogar_pensionado	Formalidad	Indicador	Alguien de la unidad de gasto recibió pensión
num_horas_ug	Formalidad	Suma	Horas semanales del trabajo principal (P6800)
num_asalariados	Formalidad	Conteo	Empleados particulares o del gobierno
num_cuentapropia	Formalidad	Conteo	Trabajadores por cuenta propia
cat_pos_jefe	Formalidad	Factor	Posición ocupacional del jefe (P6430)

Predictores del bloque extendido

Se agregan a los 21 anteriores. El Random Forest, AdaBoost y Naive Bayes usan los 43.

Variable	Bloque	Tipo	Definición
num_personas_hogar	Extendida	Conteo	Nper. Todas las personas que viven en el hogar
num_cuartos	Extendida	Conteo	P5000. Cuartos, incluida la sala-comedor
num_log_arriendo_pc	Extendida	Continua	log(arriendo por persona). 0 si no informa
bin_arriendo_nd	Extendida	Indicador	1 si el arriendo es 98 o 99 (no sabe o no informa)
num_edad_jefe	Extendida	Continua	Edad del jefe
num_edad_promedio_ug	Extendida	Promedio	Edad promedio de la unidad de gasto
prop_menores_ug	Extendida	Razón	Menores de 18 en la unidad de gasto / personas
prop_mujeres_ug	Extendida	Razón	Mujeres en la unidad de gasto / personas
num_menores_6_ug	Extendida	Conteo	Menores de 6 años en la unidad de gasto
cat_educ_jefe	Extendida	Factor	Nivel educativo del jefe
num_adultos_universitarios_ug	Extendida	Conteo	Adultos con educación universitaria en la UG
bin_jefe_ocupado	Extendida	Indicador	1 si el jefe está ocupado
num_desocupados_ug	Extendida	Conteo	Desocupados en la unidad de gasto
tasa_desempleo_ug	Extendida	Razón	Desocupados / (ocupados + desocupados)
bin_sin_activos_ug	Extendida	Indicador	1 si no hay ocupados ni desocupados
num_estudiantes_ug	Extendida	Conteo	Estudiaron la mayor parte de la semana (P6240)
prop_cotizantes_ocupados_ug	Extendida	Razón	Cotizantes / ocupados. 0 si no hay ocupados
num_no_afiliados_salud_ug	Extendida	Conteo	No afiliados a salud (P6090 = 2)
num_subempleo_ug	Extendida	Conteo	Ocupados que quieren trabajar más horas
bin_prima_servicios_ug	Extendida	Indicador	Alguien recibió prima de servicios
bin_dinero_hogares_ug	Extendida	Indicador	Alguien recibió dinero de otros hogares
cat_tam_empresa_jefe	Extendida	Factor	Tamaño de la empresa donde trabaja el jefe

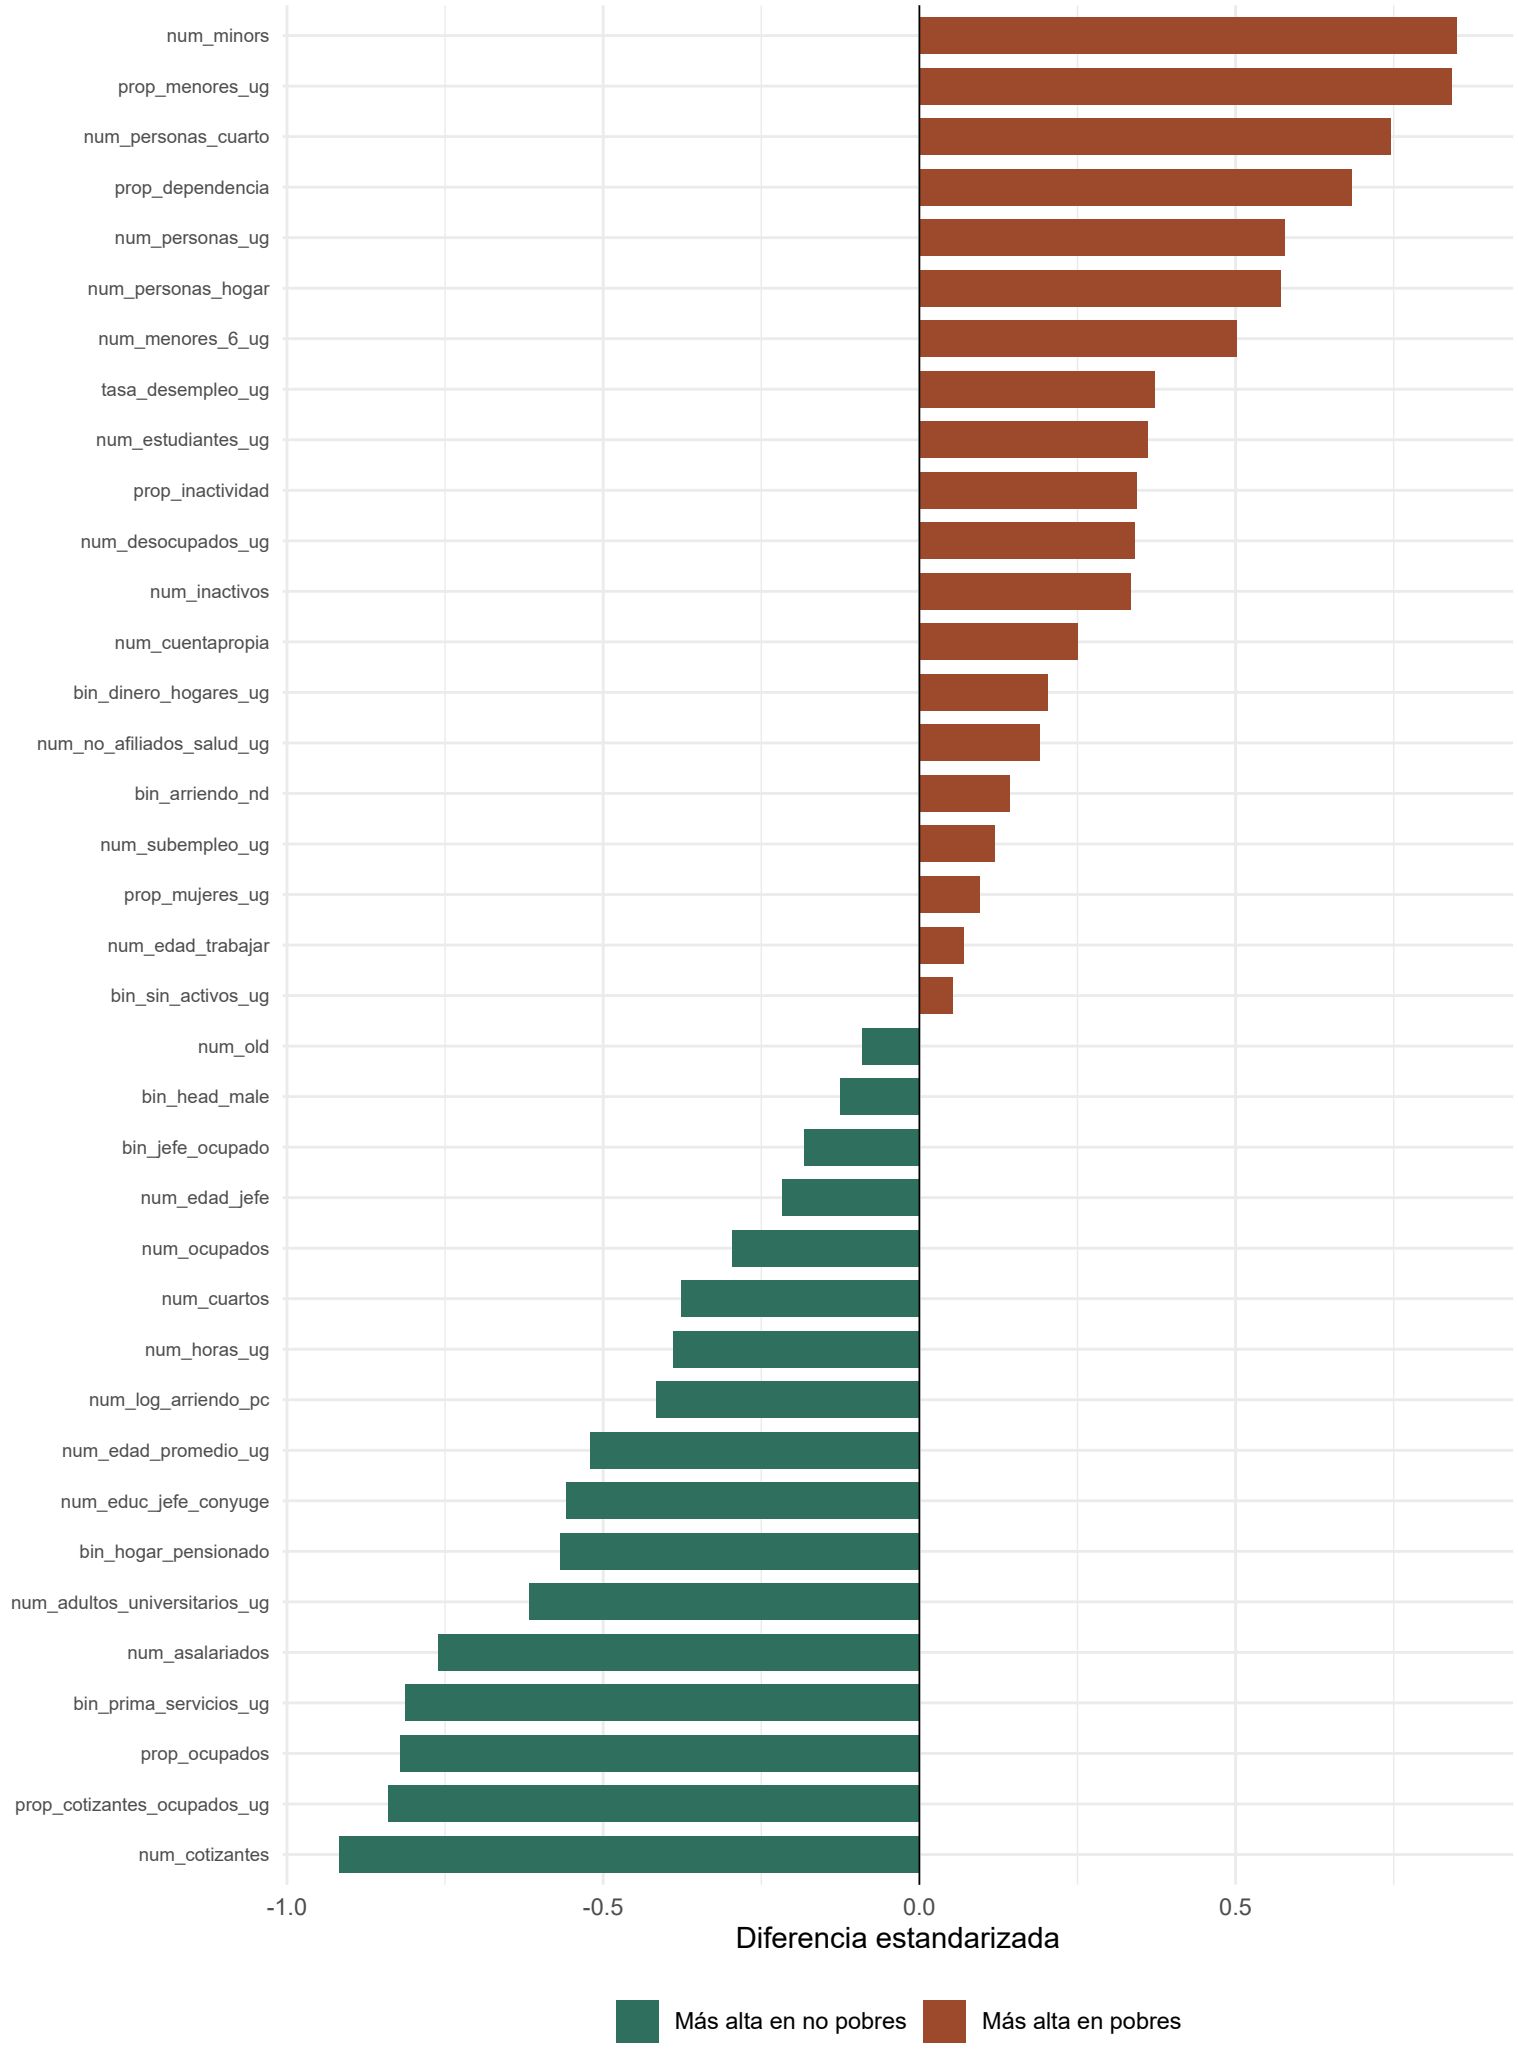
Indicadores: pobreza cuando valen 0 y cuando valen 1

La pobreza de todo el train es 20.0%. La diferencia está en puntos porcentuales (vale 1 menos vale 0).

Indicador	Hogares en 1	Pobreza si es 0	Pobreza si es 1	Diferencia, pp
bin_prima_servicios_ug	55,269	27.8%	4.7%	-23.1
bin_hogar_pensionado	22,961	23.0%	1.9%	-21.1
bin_arriendo_nd	10,421	19.4%	29.5%	+10.1
bin_dinero_hogares_ug	36,958	18.2%	26.3%	+8.0
bin_jefe_ocupado	117,156	24.7%	18.1%	-6.6
bin_head_male	95,959	22.4%	18.3%	-4.1
bin_sin_activos_ug	16,866	19.7%	22.6%	+2.8

Qué tan distinta es cada variable entre pobres y no pobres

SMD = (media en pobres − media en no pobres) / desviación pooled. Importa el tamaño, no el p-valor.



Distribución de las variables que más separan

Ordenadas por el valor absoluto del SMD. La mediana es de cada clase. El porcentaje en cero es de todo el train.

Variable	Mediana pobre	Mediana no pobre	% en cero	SMD
num_cotizantes	0.00	1.00	56.8%	-0.92
num_minors	2.00	0.00	47.4%	+0.85
prop_menores_ug	0.40	0.00	47.4%	+0.84
prop_cotizantes_ocupados_ug	0.00	0.25	56.8%	-0.84
prop_ocupados	0.25	0.50	13.7%	-0.82
bin_prima_servicios_ug	0.00	0.00	66.5%	-0.81
num_asalariados	0.00	1.00	52.8%	-0.76
num_personas_cuarto	1.33	1.00	0.0%	+0.75
prop_dependencia	1.00	0.33	37.5%	+0.68
num_adultos_universitarios_ug	0.00	1.00	51.8%	-0.62
num_personas_ug	4.00	3.00	0.0%	+0.58
num_personas_hogar	4.00	3.00	0.0%	+0.57
bin_hogar_pensionado	0.00	0.00	86.1%	-0.57
num_educ_jefe_conyuge	4.00	5.00	0.0%	-0.56
num_edad_promedio_ug	25.50	35.50	0.0%	-0.52
num_menores_6_ug	0.00	0.00	76.8%	+0.50
num_log_arriendo_pc	11.00	11.85	6.3%	-0.42
num_horas_ug	48.00	60.00	13.7%	-0.39
num_cuartos	3.00	3.00	0.0%	-0.38

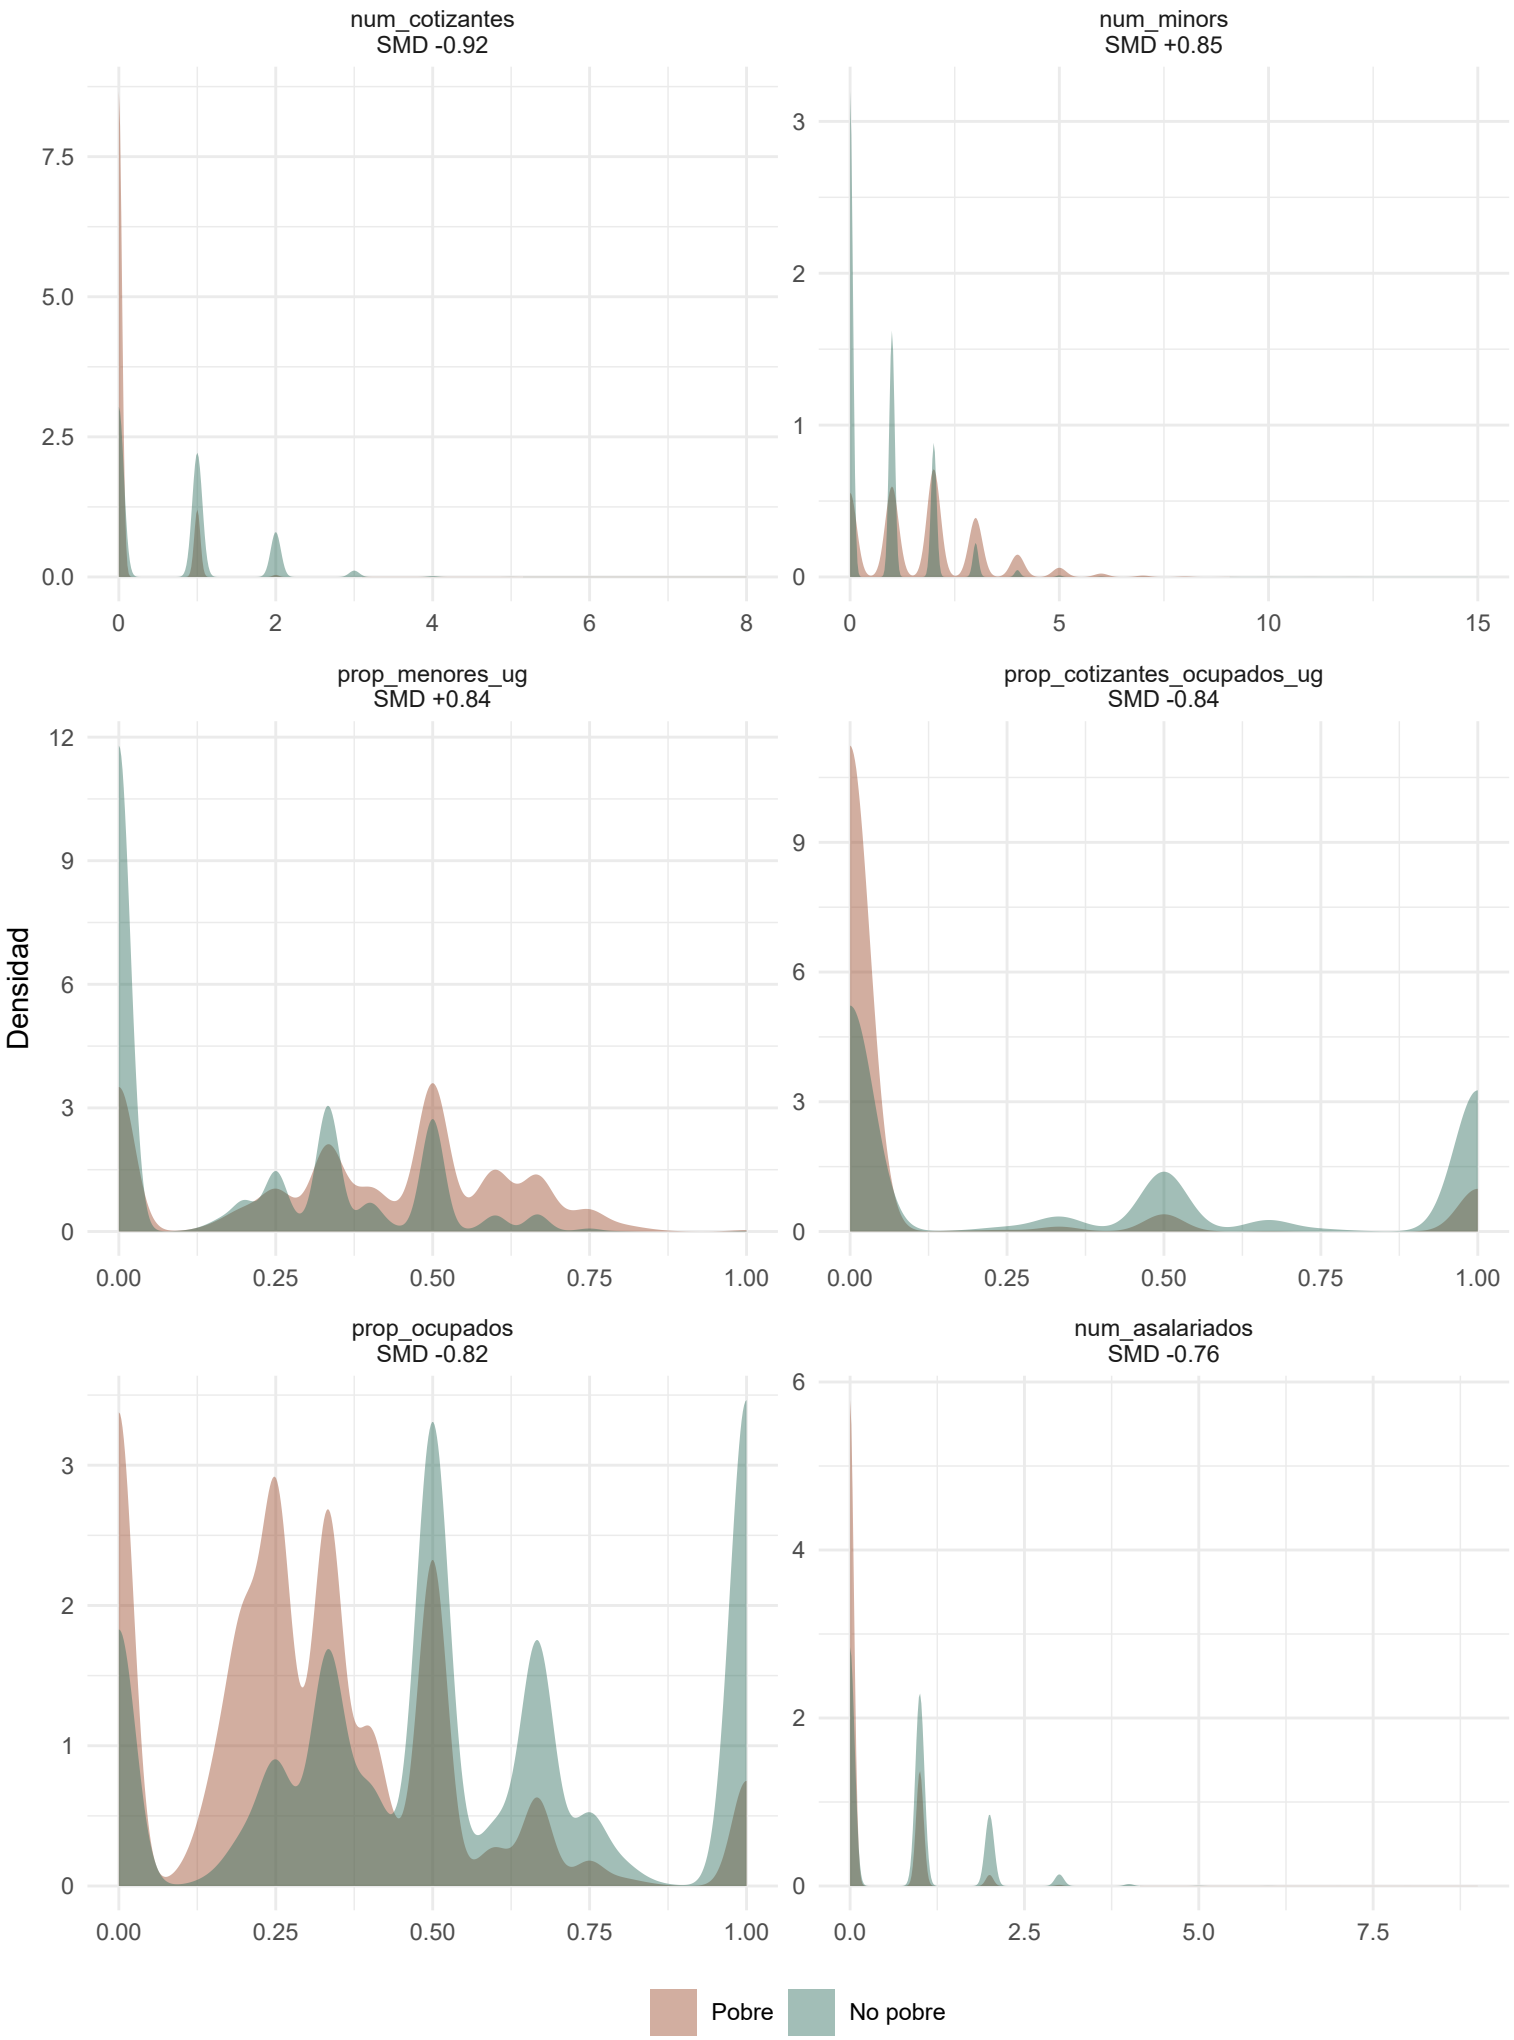
Distribución del resto de variables numéricas

Las de esta página separan menos las dos clases. Siguen entrando al modelo.

Variable	Mediana pobre	Mediana no pobre	% en cero	SMD
tasa_desempleo_ug	0.00	0.00	84.0%	+0.37
num_estudiantes_ug	0.00	0.00	67.1%	+0.36
prop_inactividad	0.25	0.00	60.6%	+0.34
num_desocupados_ug	0.00	0.00	84.0%	+0.34
num_inactivos	1.00	0.00	60.6%	+0.34
num_ocupados	1.00	1.00	13.7%	-0.30
num_cuentapropia	1.00	0.00	48.5%	+0.25
num_edad_jefe	45.00	50.00	0.0%	-0.22
bin_dinero_hogares_ug	0.00	0.00	77.6%	+0.20
num_no_afiliados_salud_ug	0.00	0.00	87.9%	+0.19
bin_jefe_ocupado	1.00	1.00	29.0%	-0.18
bin_arriendo_nd	0.00	0.00	93.7%	+0.14
bin_head_male	1.00	1.00	41.8%	-0.12
num_subempleo_ug	0.00	0.00	88.5%	+0.12
prop_mujeres_ug	0.50	0.50	10.1%	+0.10
num_old	0.00	0.00	76.5%	-0.09
num_edad_trabajar	2.00	2.00	6.4%	+0.07
bin_sin_activos_ug	0.00	0.00	89.8%	+0.05

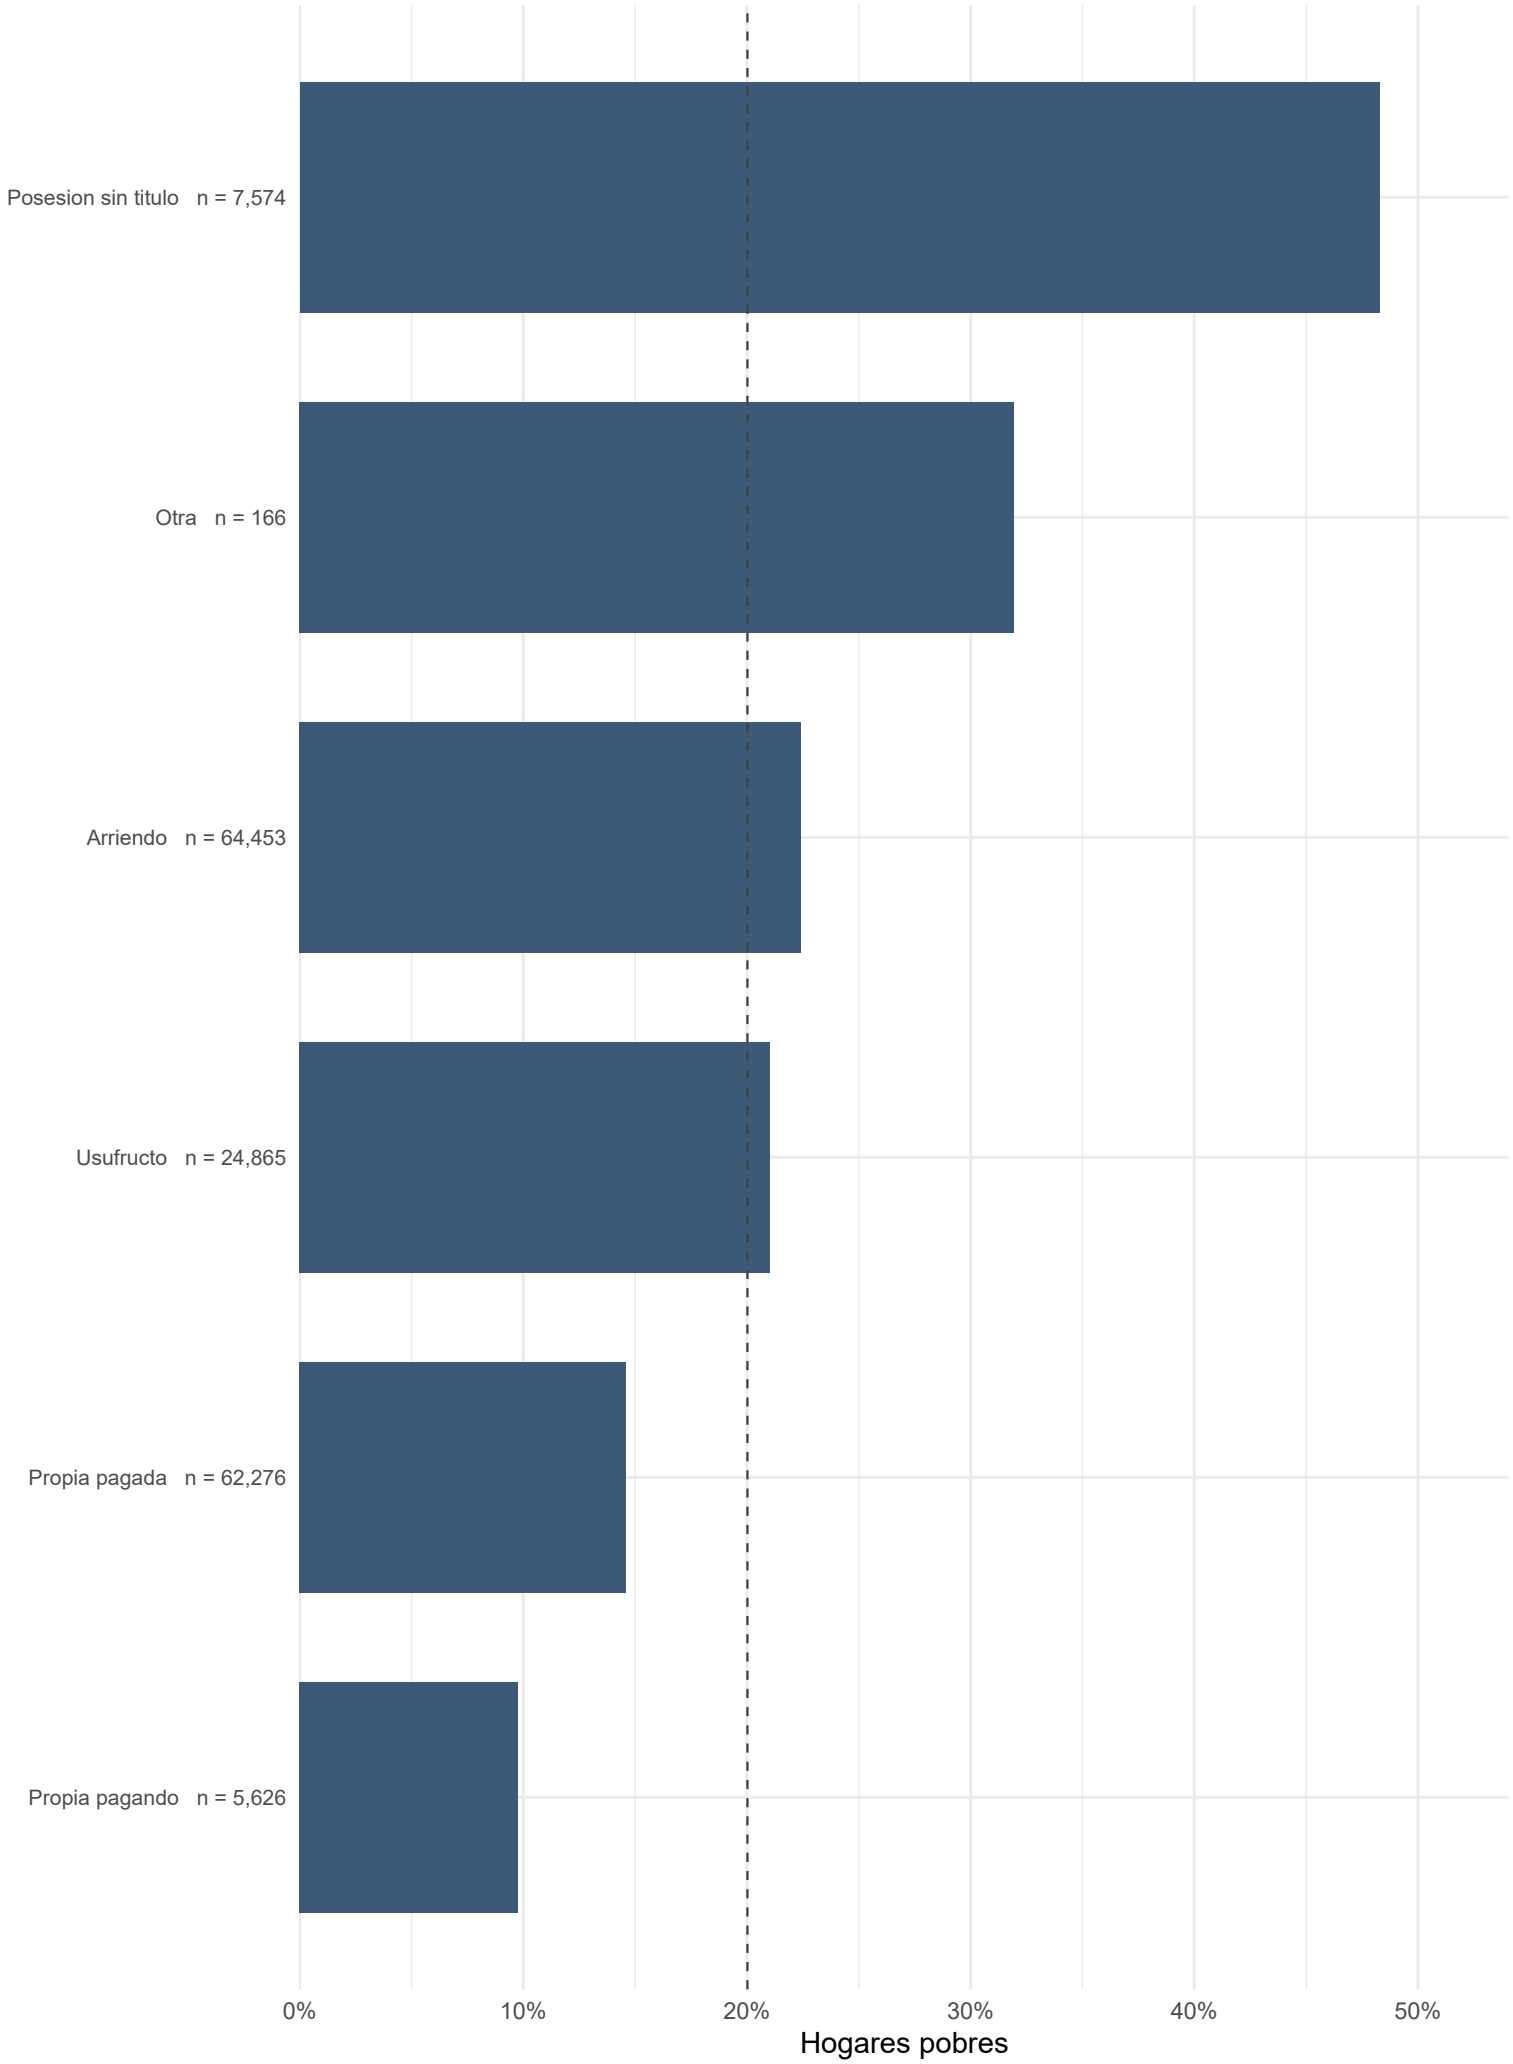
Distribución de las seis variables continuas que más separan

Densidad dentro de cada clase. Las escalas horizontales no se comparten: las unidades son distintas.



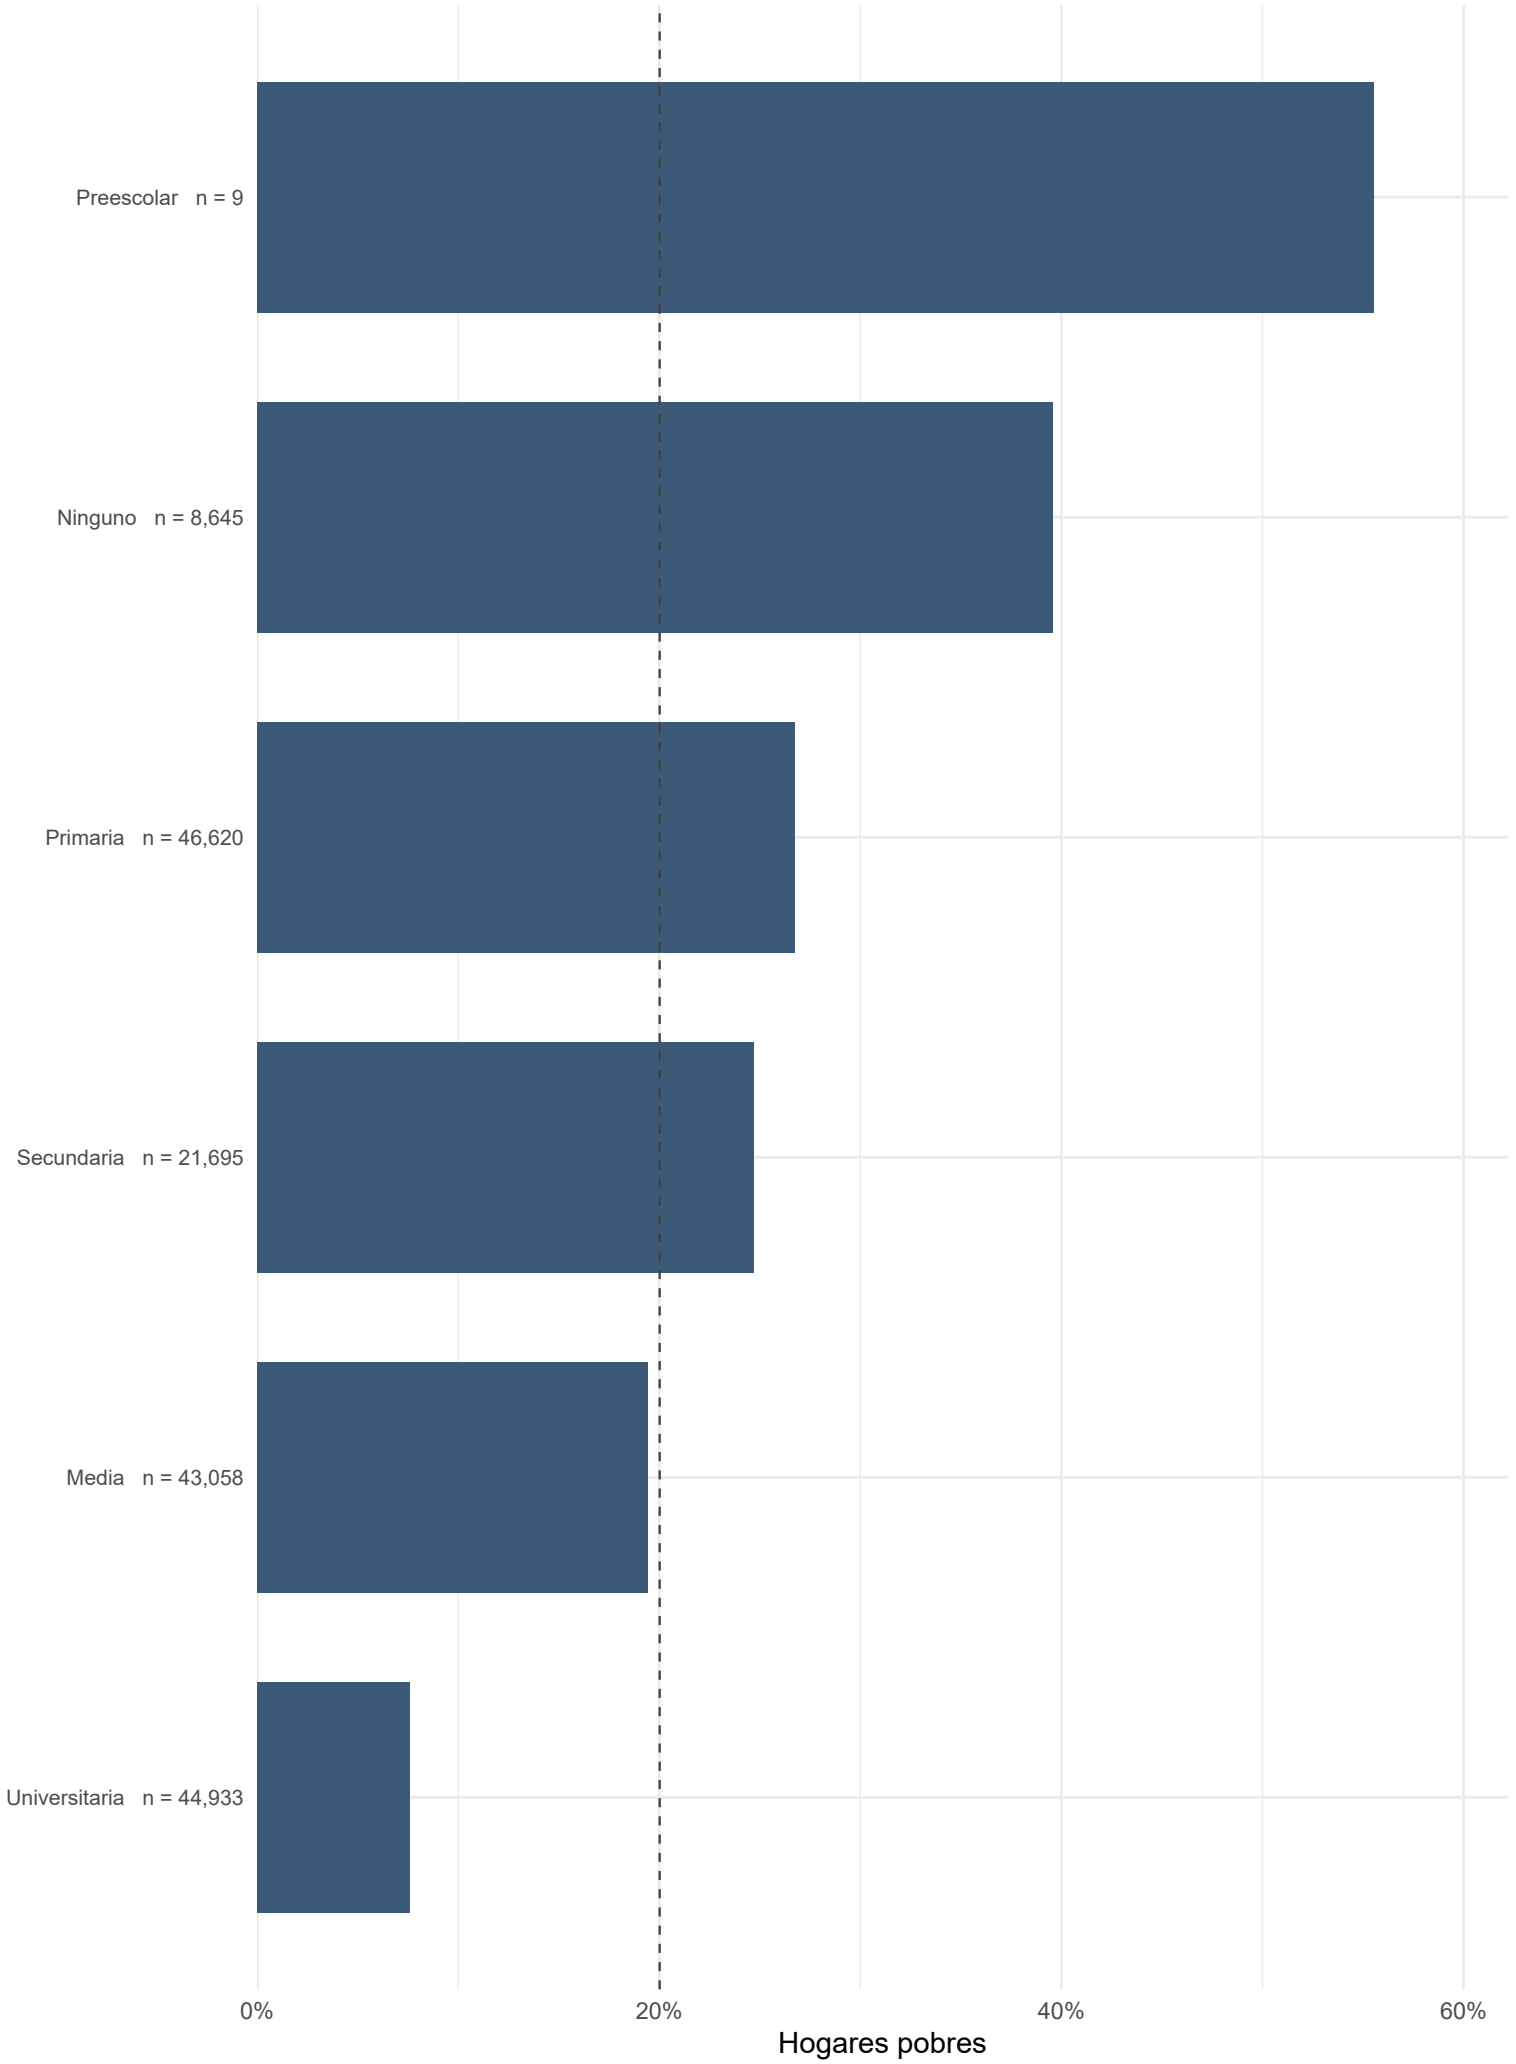
Pobreza según la tenencia de la vivienda

Línea punteada: 20.0% de los hogares de train son pobres.



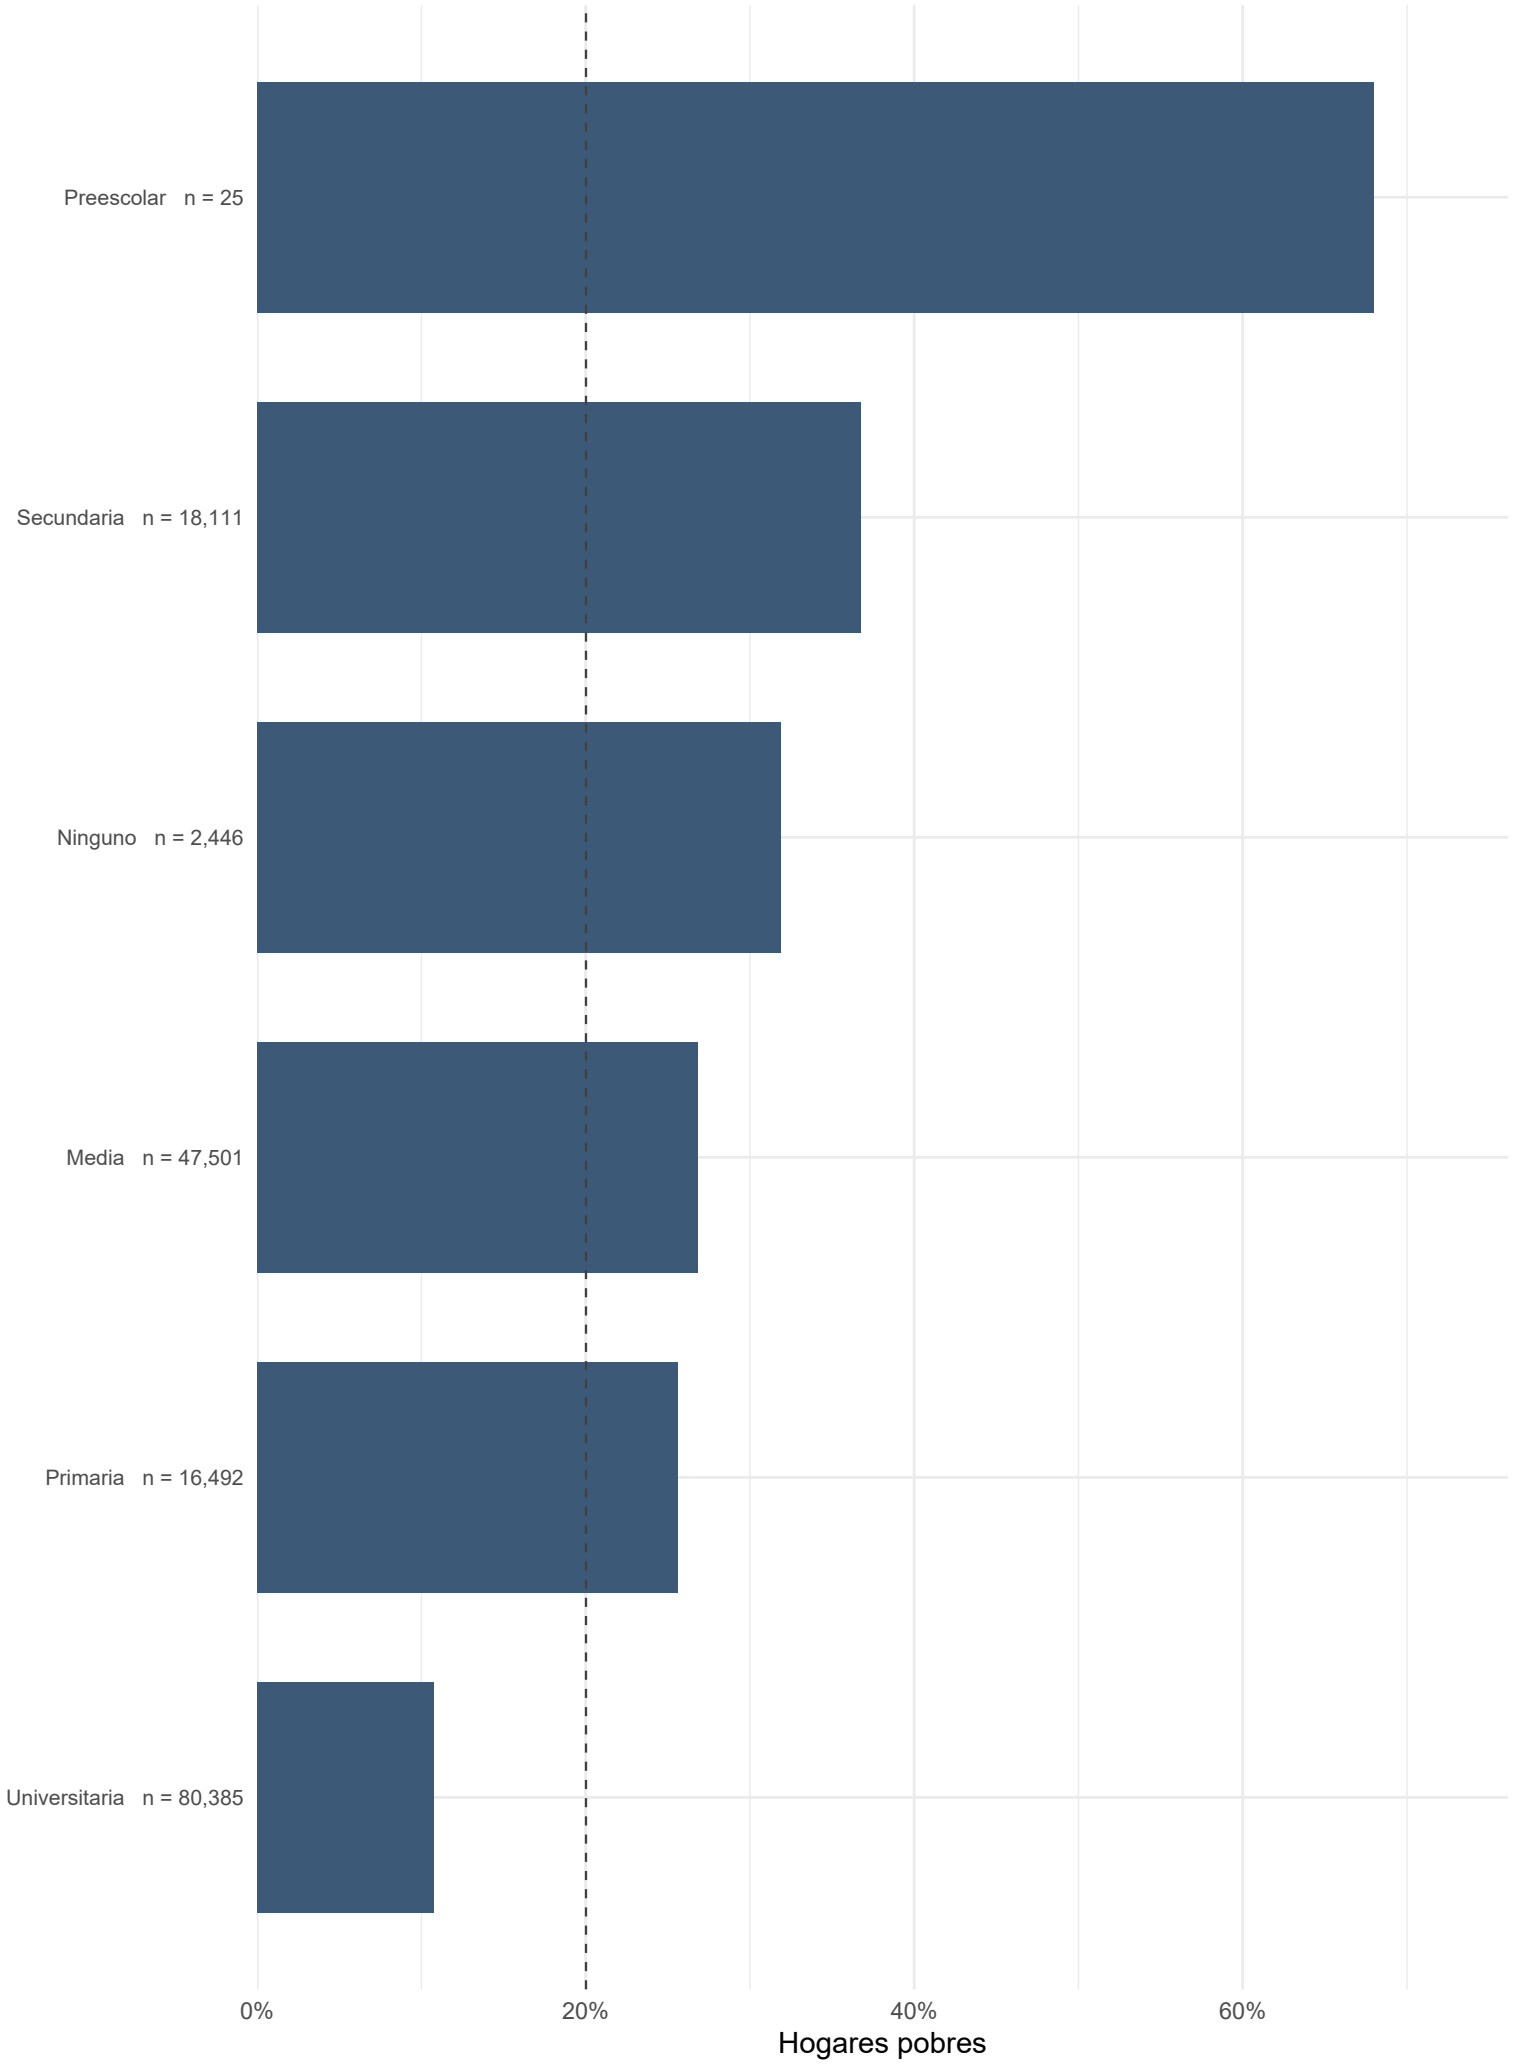
Pobreza según la educación del jefe

Ninguno incluye a quien no responde y a los menores de 3 años, por la regla de limpieza.



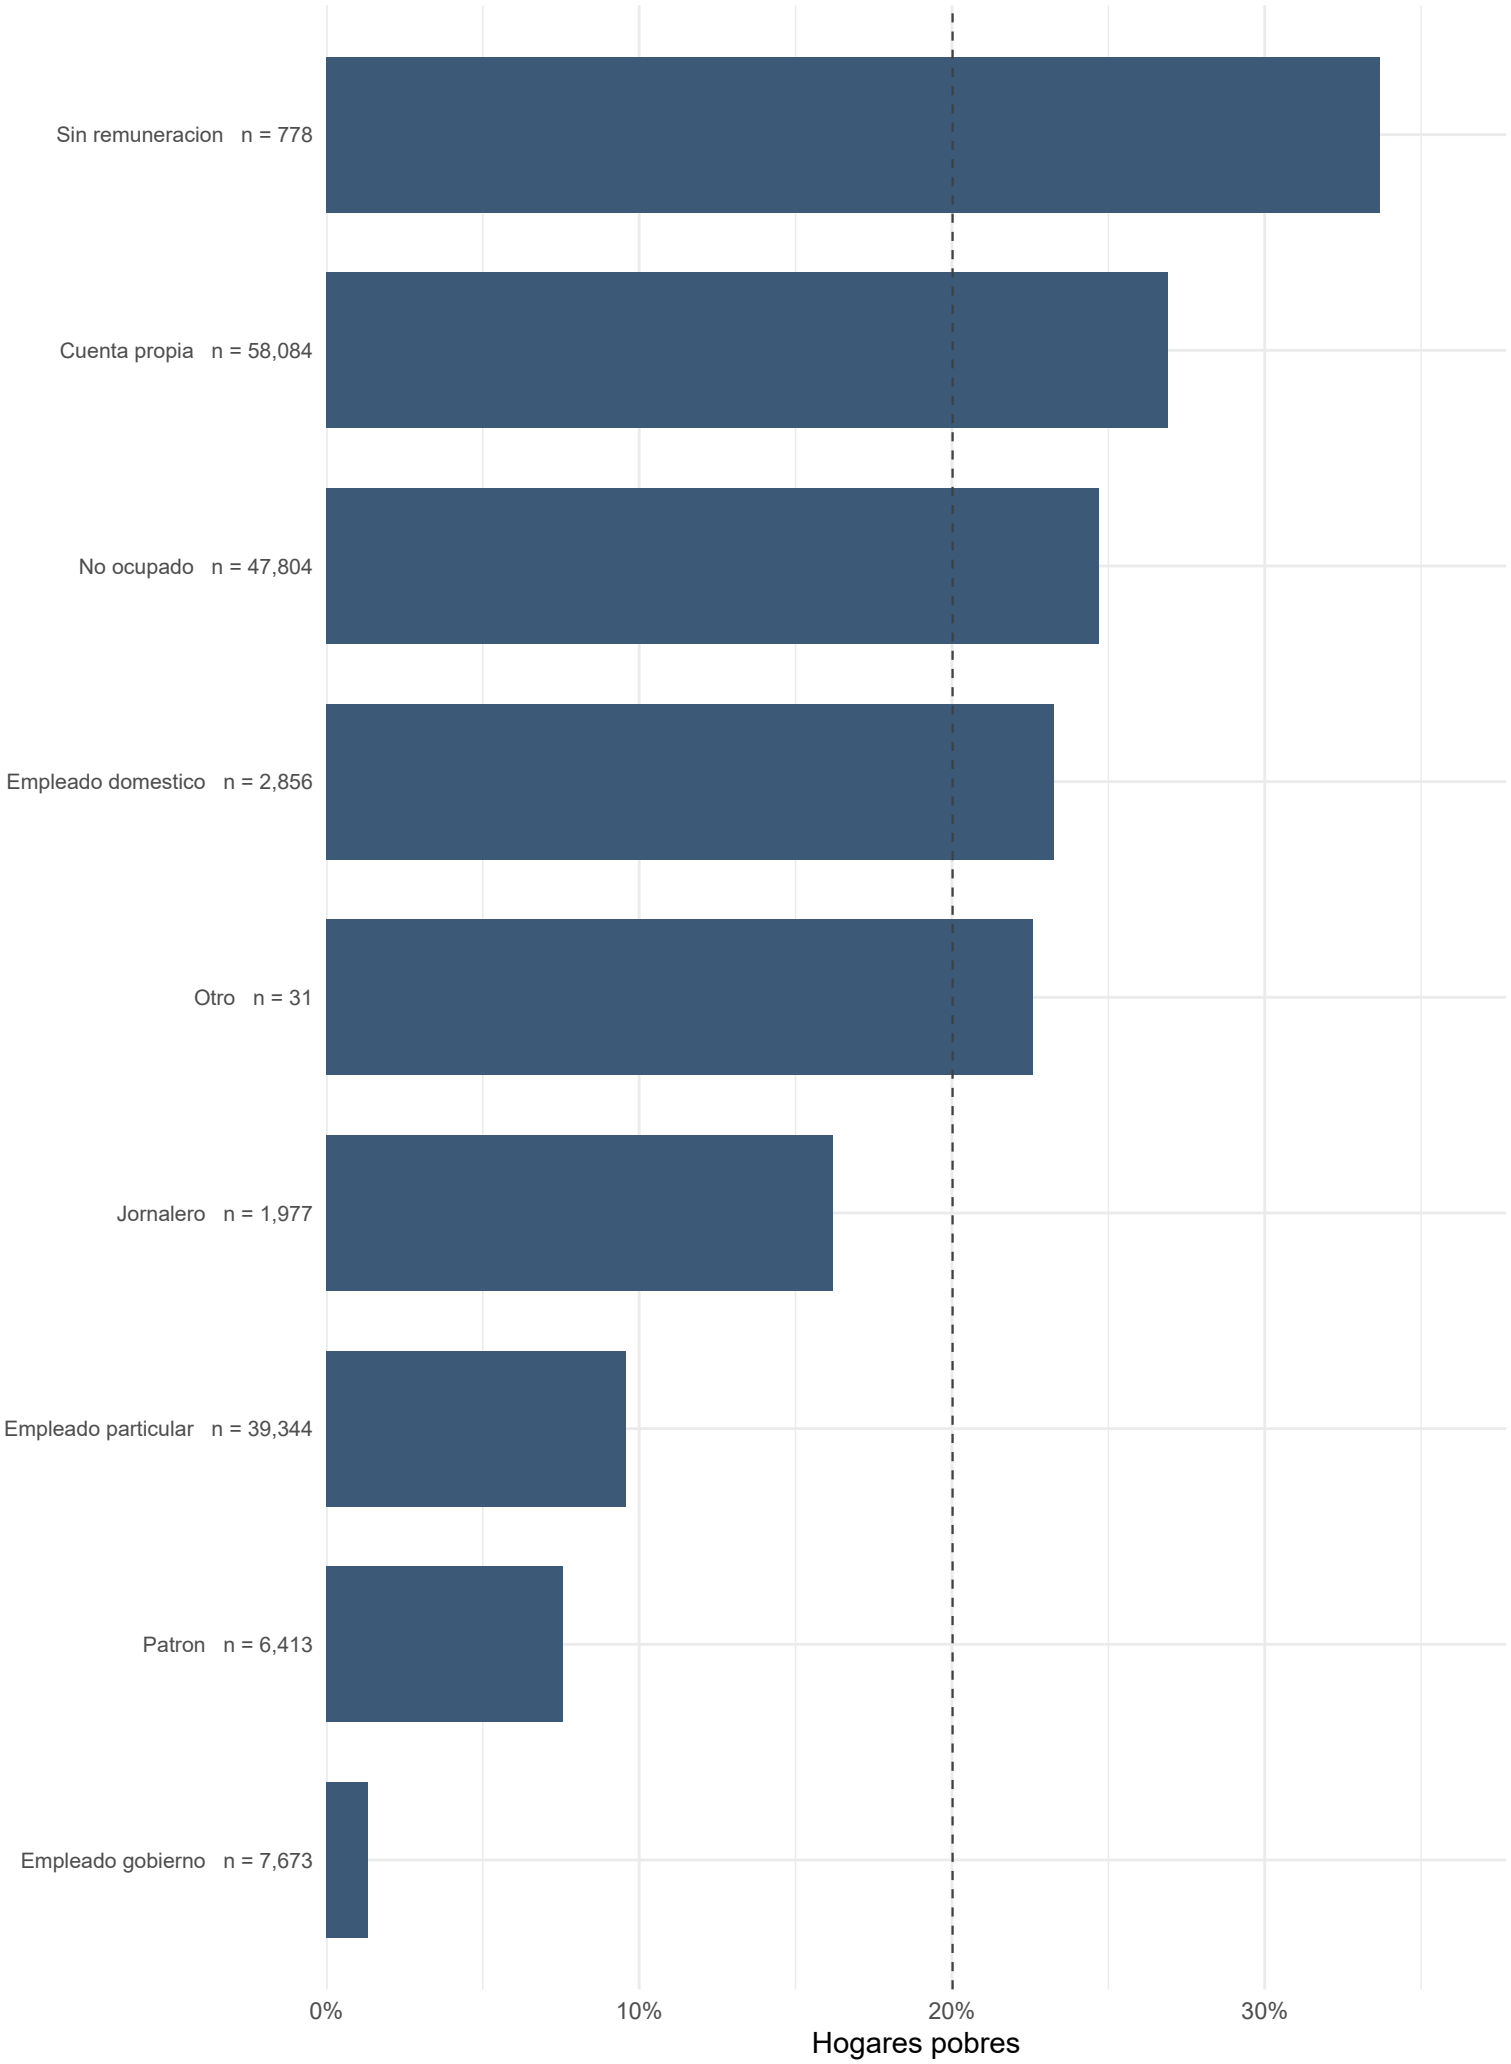
Pobreza según la educación más alta del hogar

Es el máximo entre los miembros, no solo el jefe.



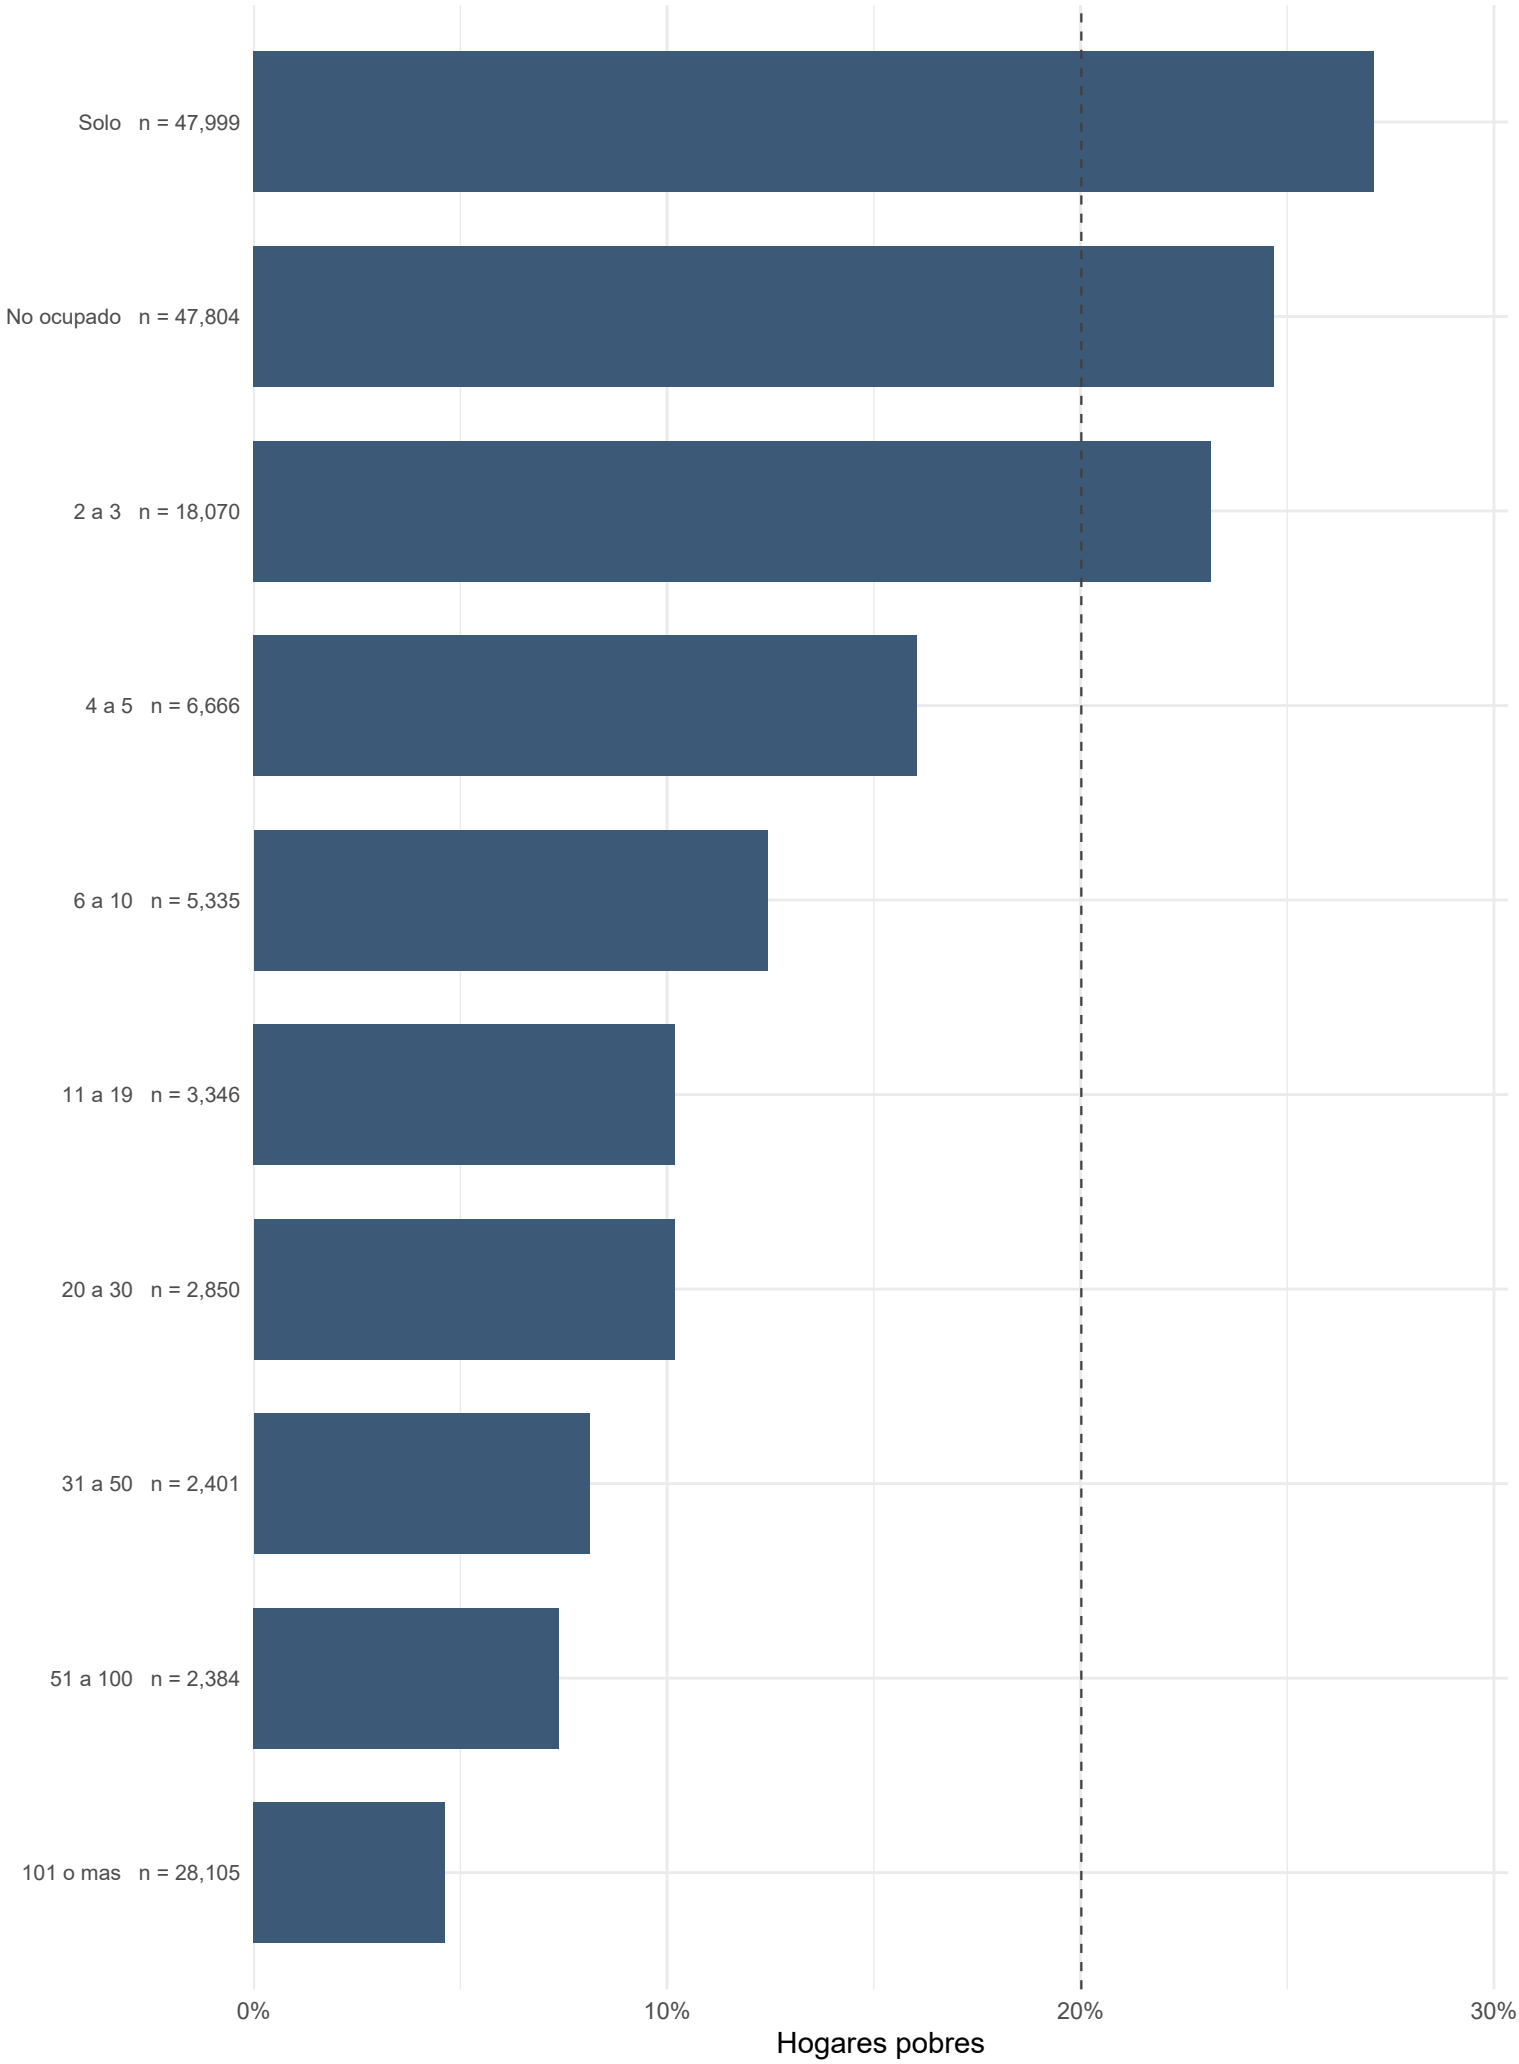
Pobreza según la posición ocupacional del jefe

Quien no trabaja queda en No ocupado. Sin remuneración junta dos códigos poco frecuentes.



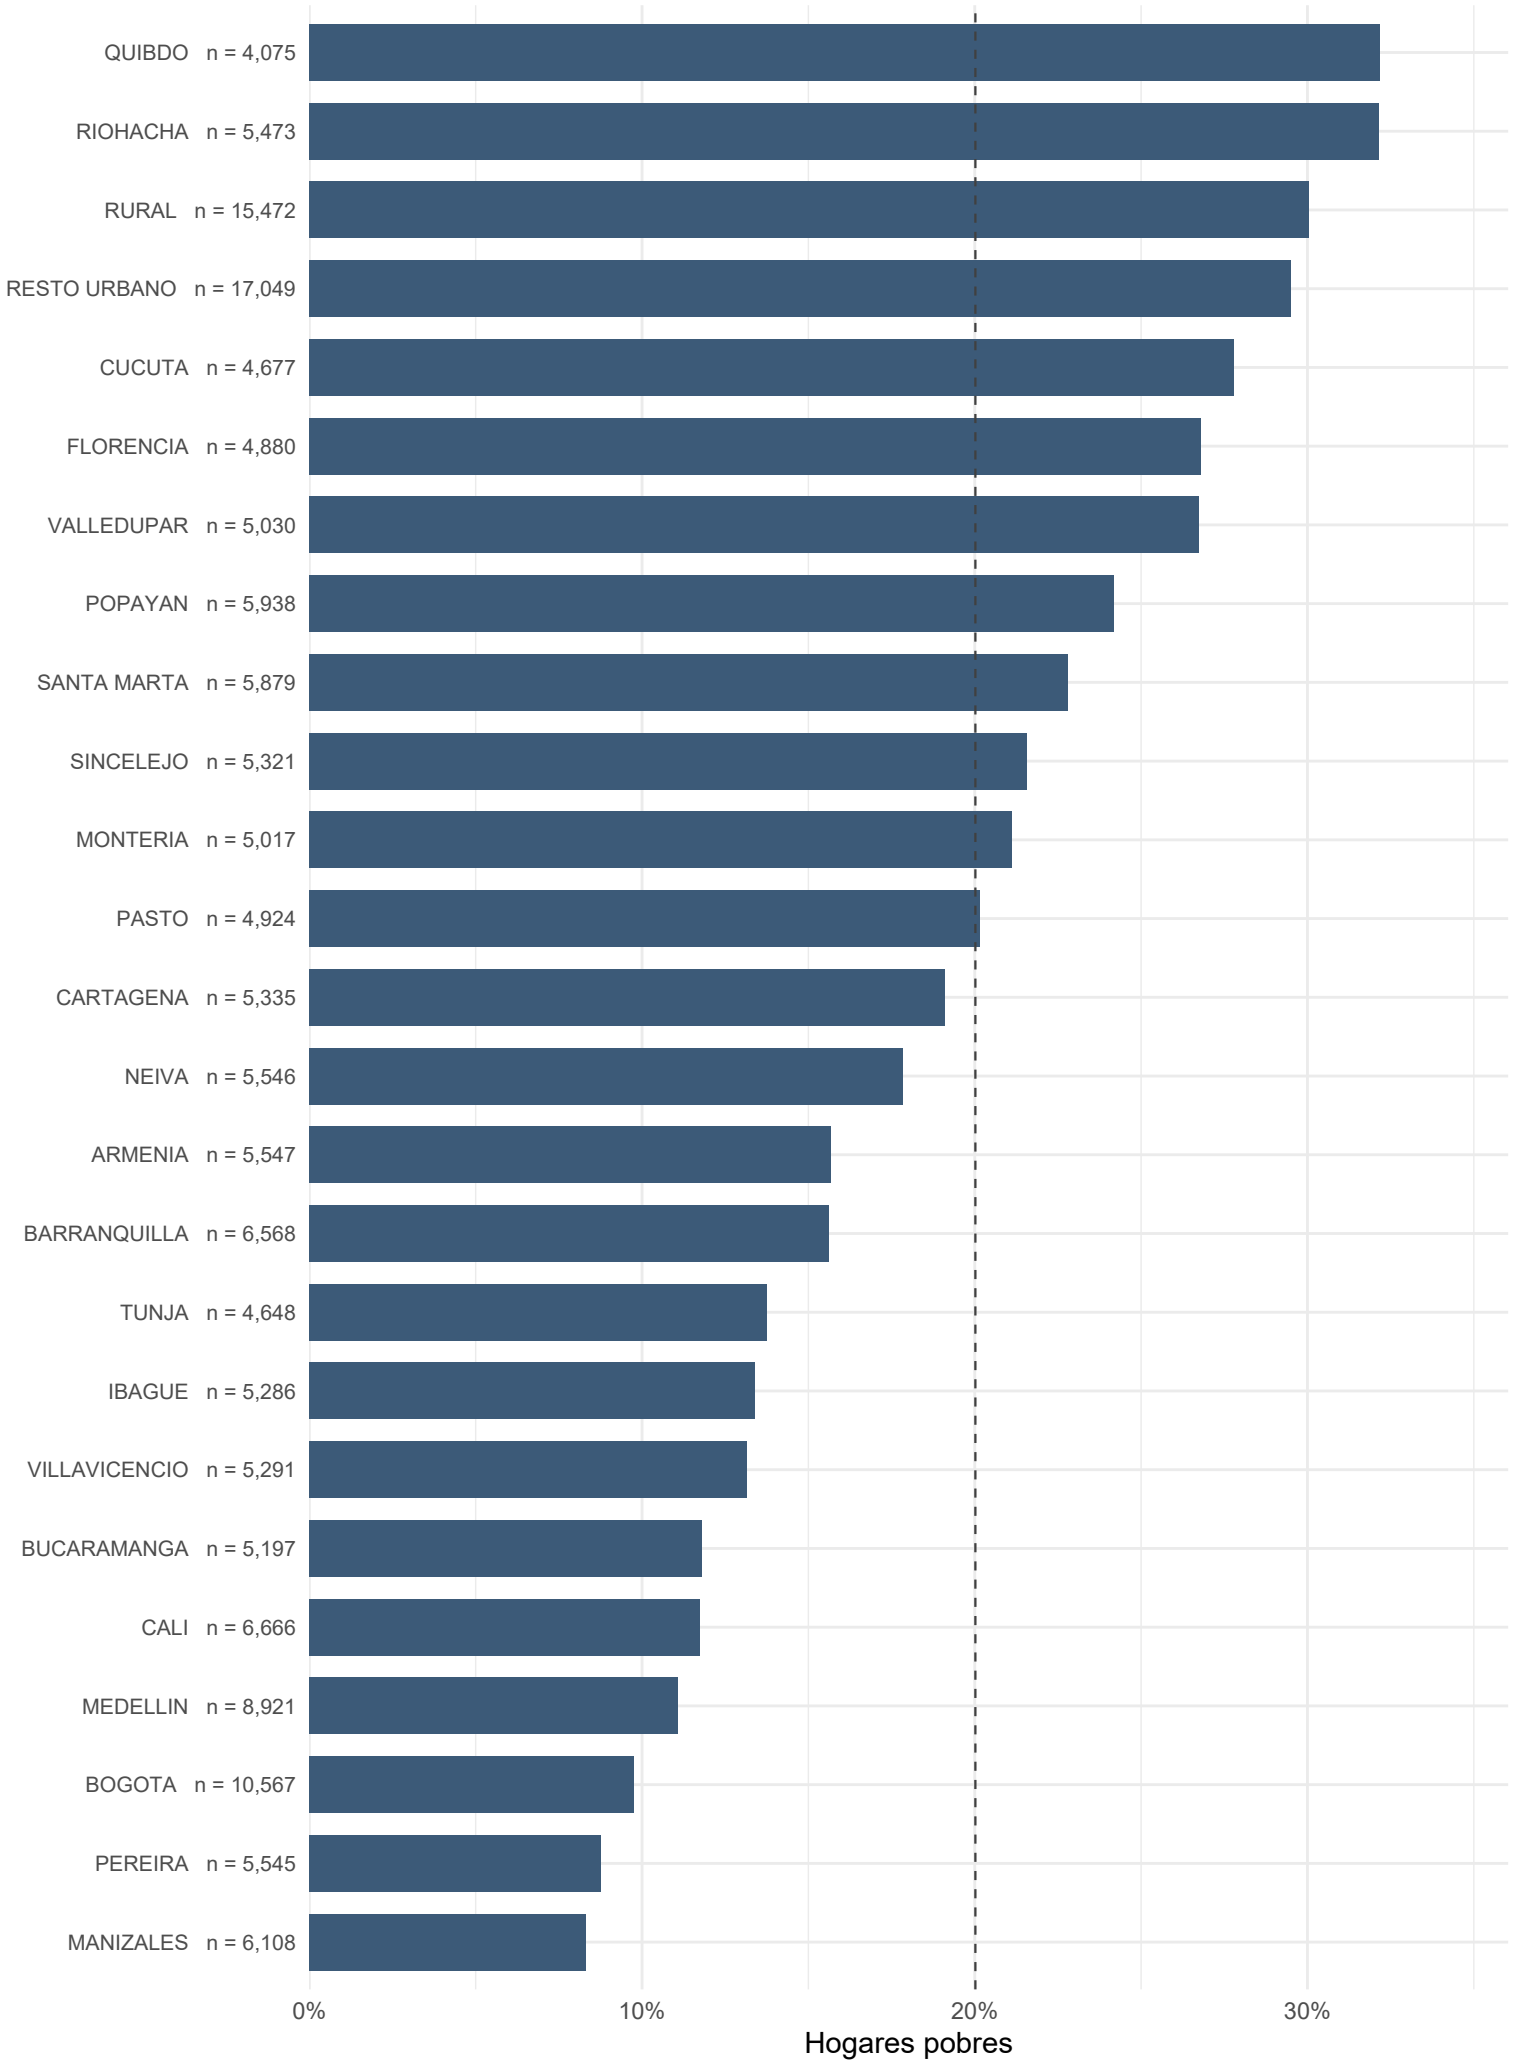
Pobreza según el tamaño de la empresa del jefe

No ocupado es el jefe que no está trabajando. El resto es el número de personas de la empresa.



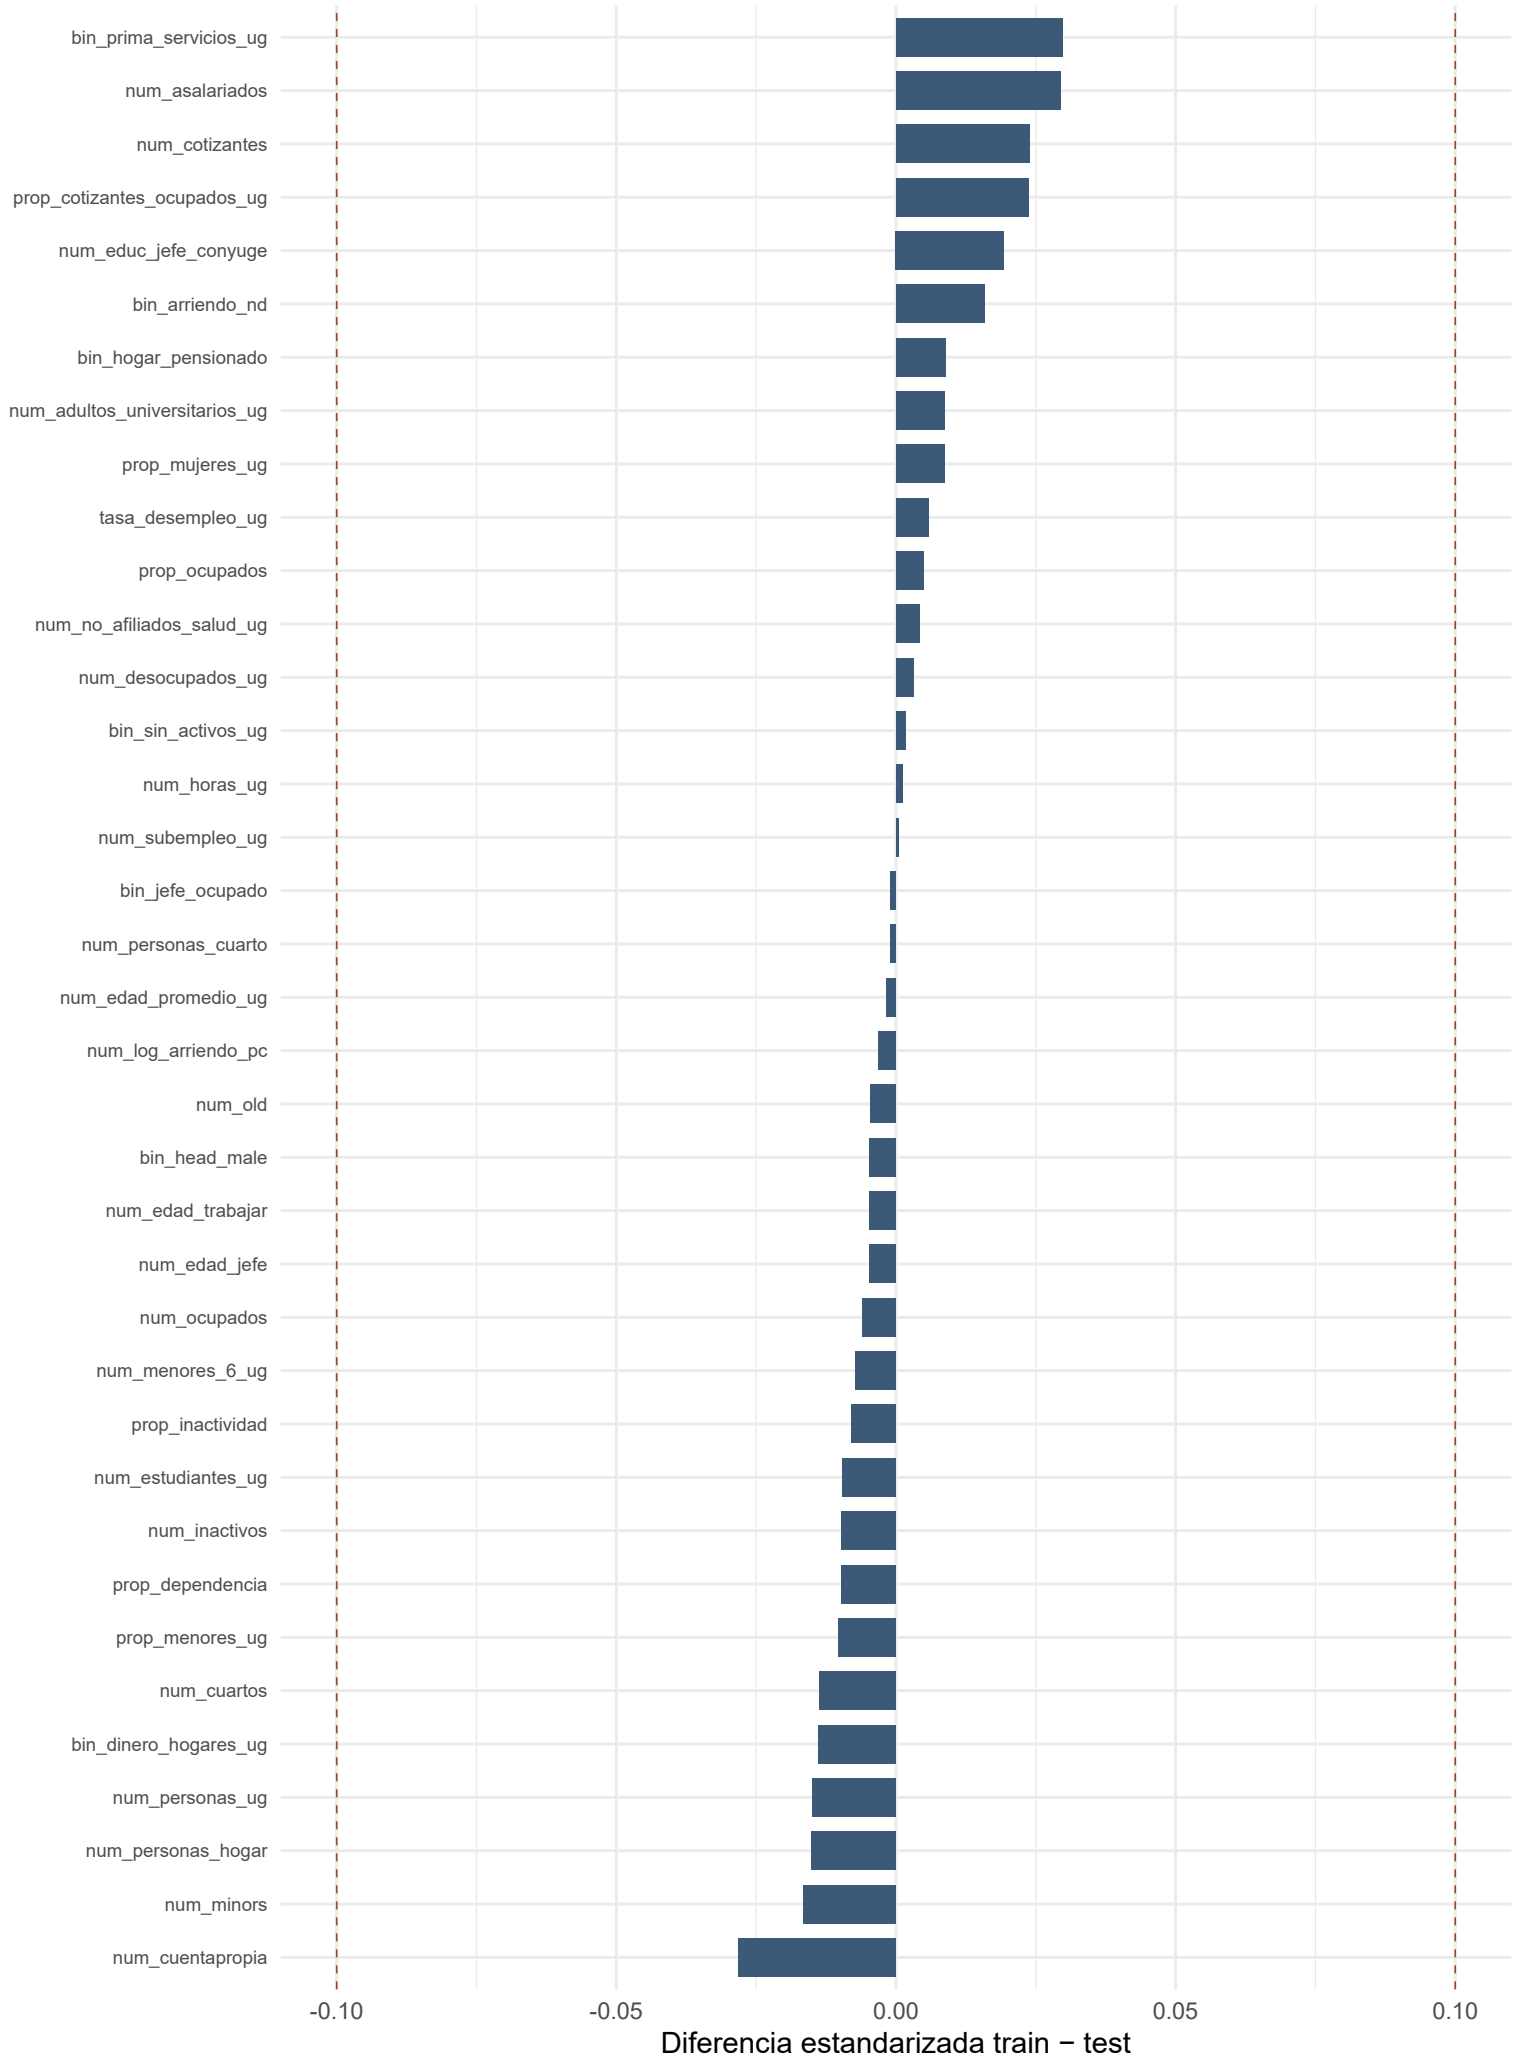
Pobreza según la ciudad o la zona

Bogotá entra en este gráfico y no está en el test. La línea es la pobreza de todo el train.



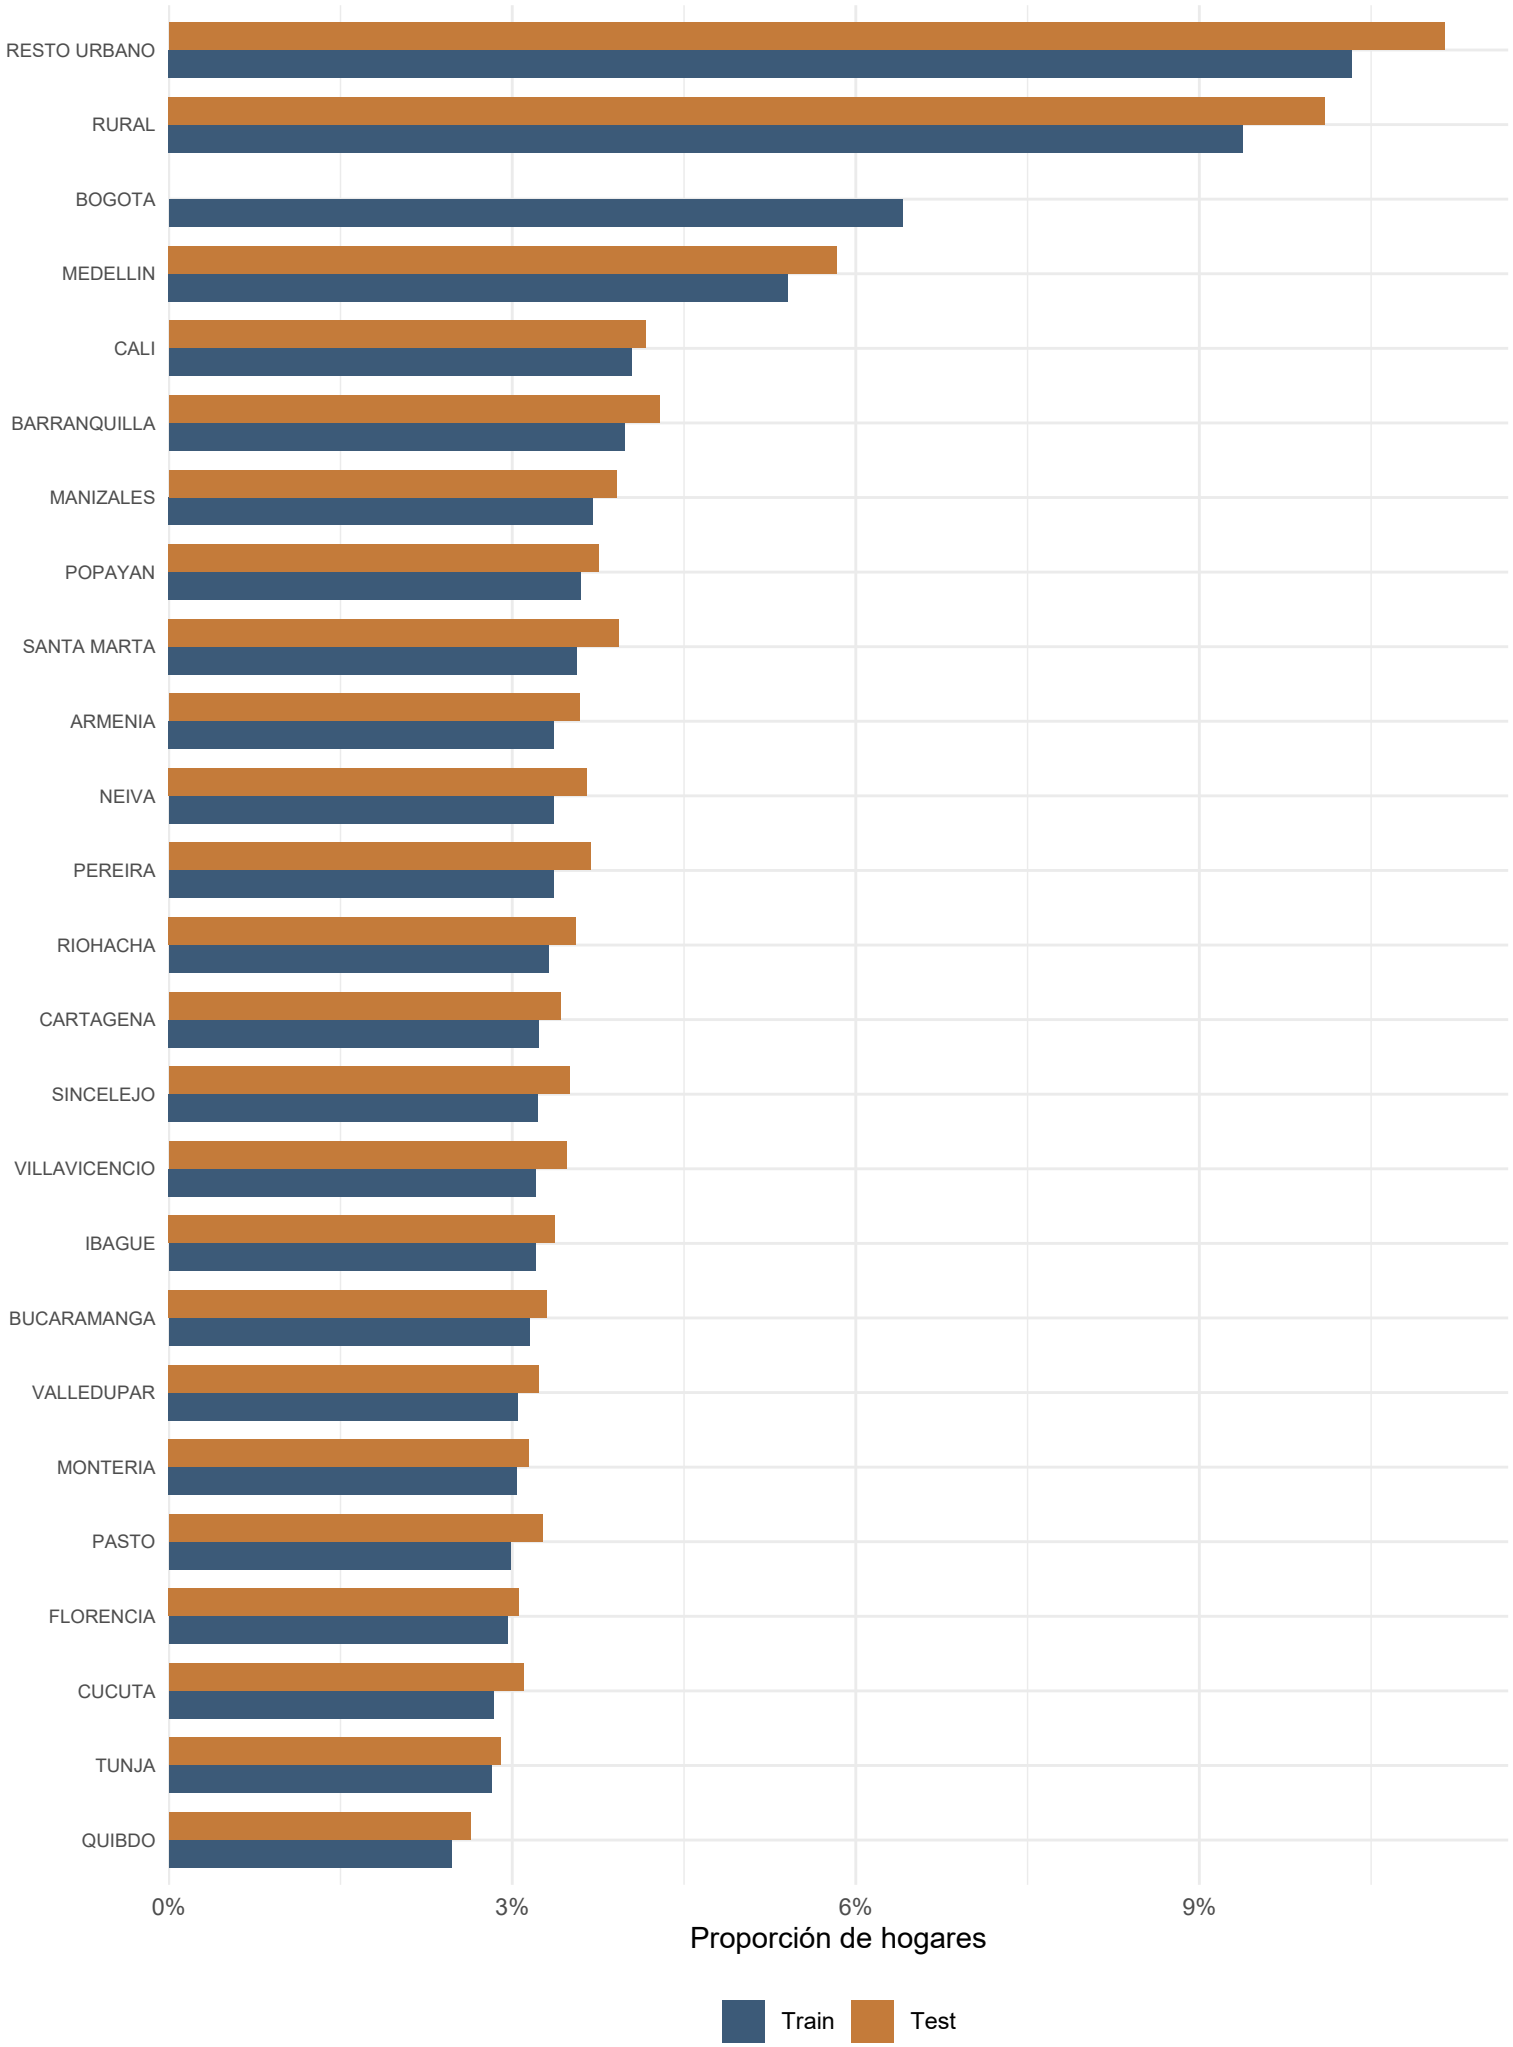
Train y test, ¿traen los mismos predictores?

SMD = (media train − media test) / desviación pooled. Líneas en ±0,1. Variables que pasan de 0,1: 0.



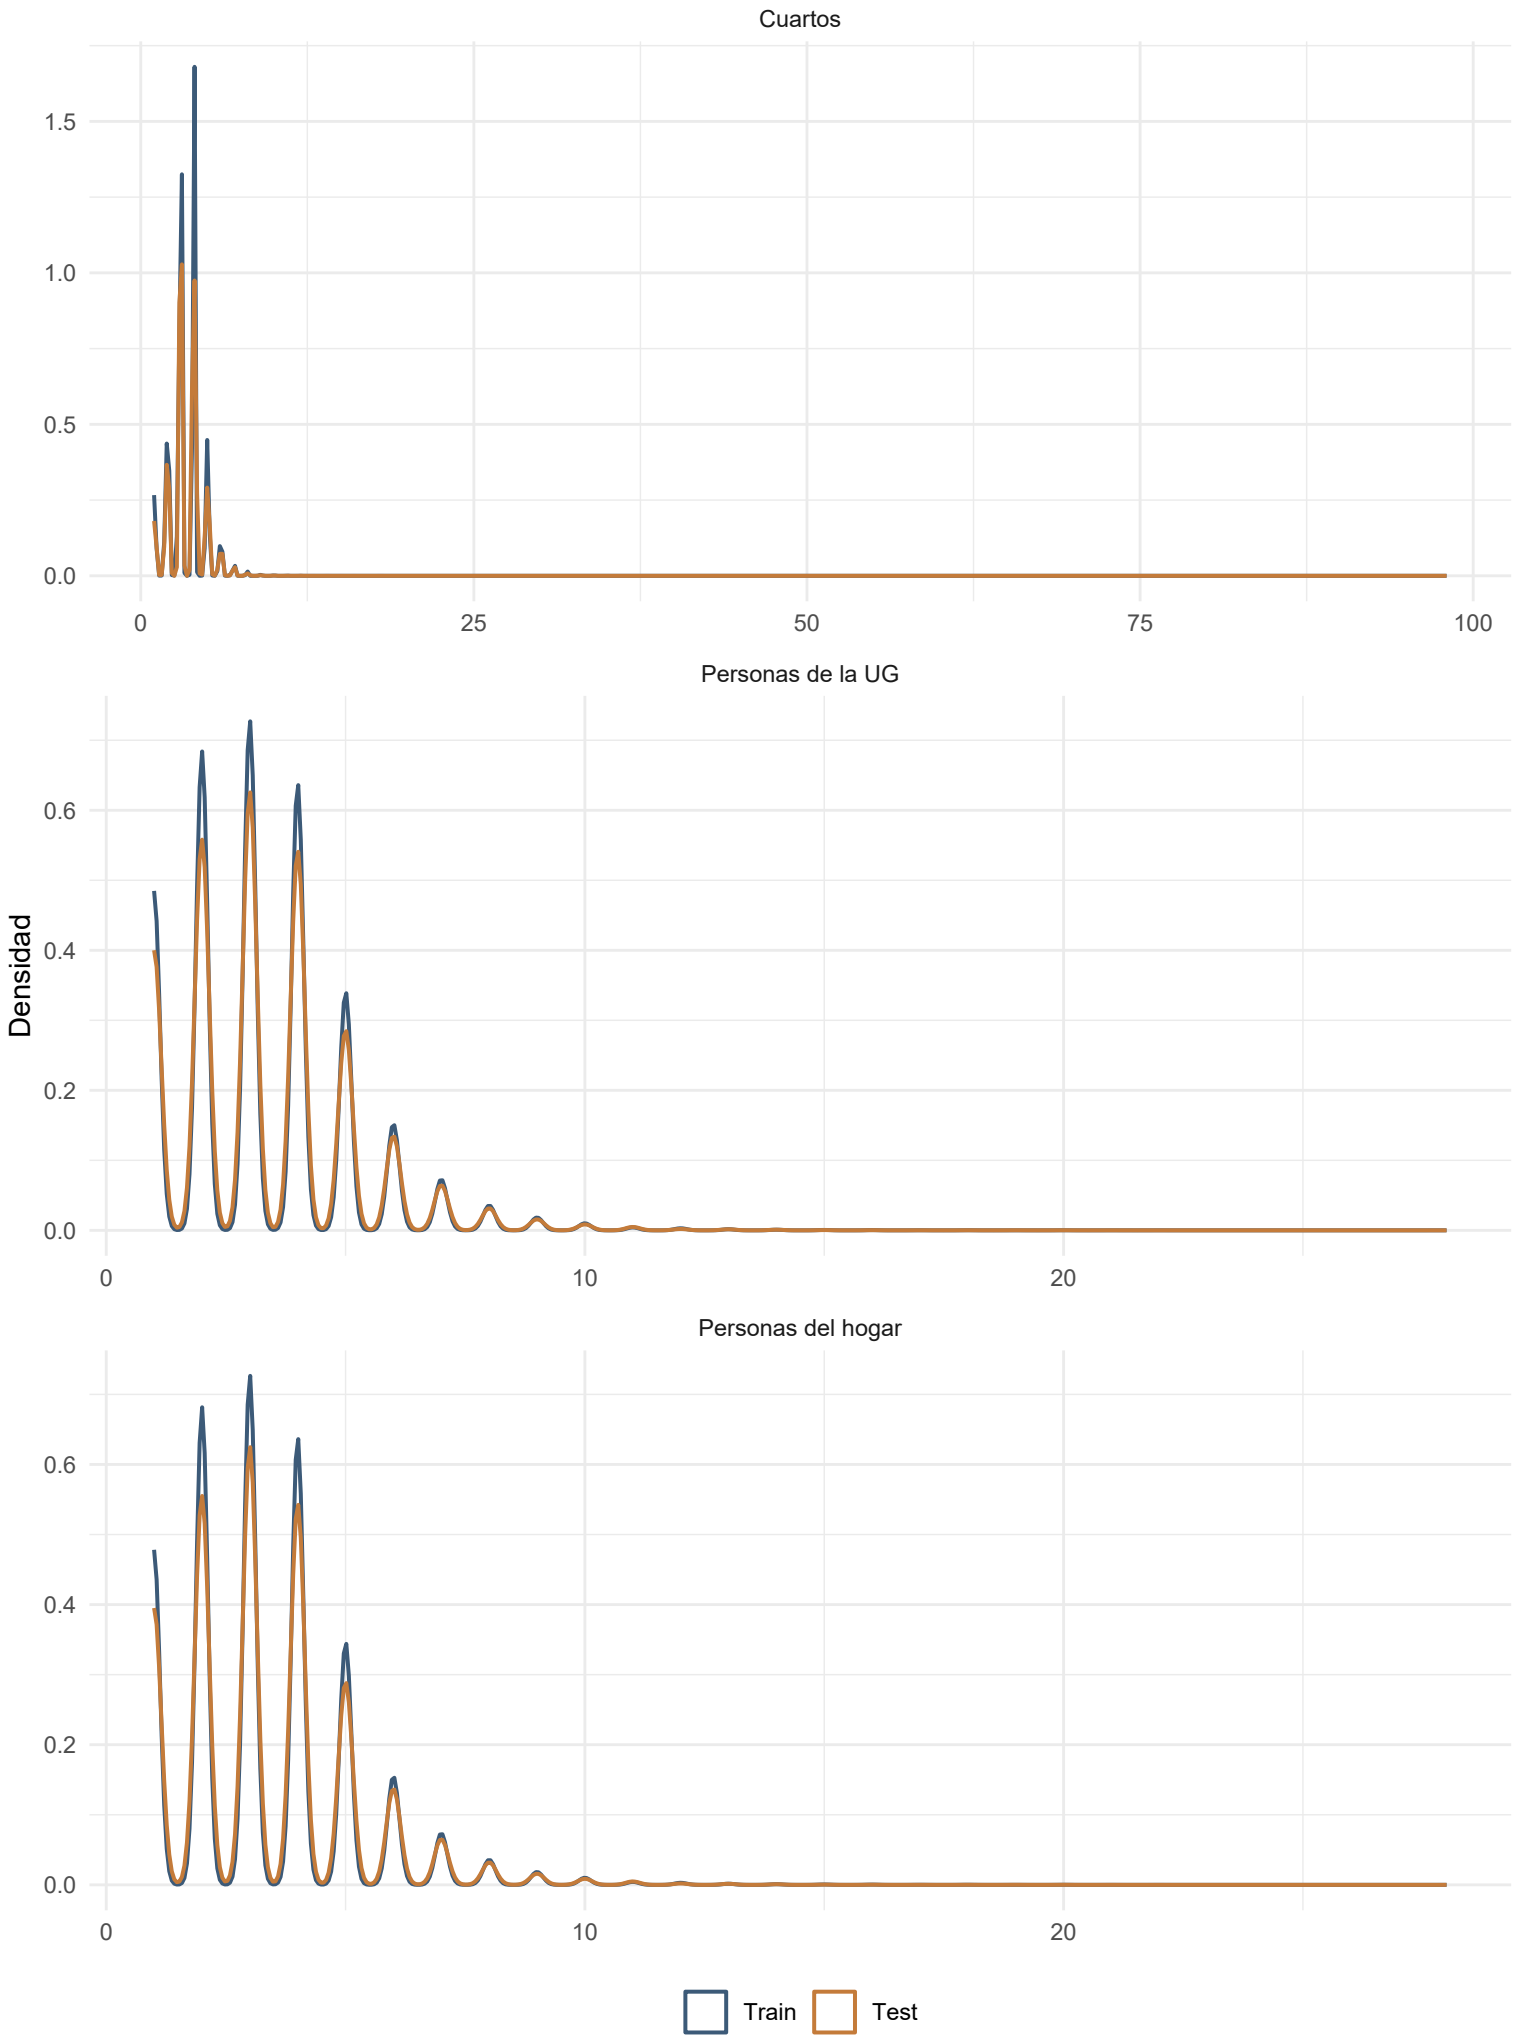
Dónde están los hogares

Proporción de hogares por Dominio. Bogotá queda en cero en el test porque el factor existe, pero no hay hogares.



Tamaño del hogar en train y en test

Densidad. Personas del hogar es Nper. La unidad de gasto excluye servicio doméstico, pensionistas y trabajadores.



Variables numéricas que se parecen mucho

Pares con correlación de Pearson mayor o igual a 0,75 en valor absoluto, calculada en train.

A	B	r
num_personas_ug	num_personas_hogar	1.00
num_log_arriendo_pc	bin_arriendo_nd	-0.96
num_ocupados	num_horas_ug	0.91
num_minors	prop_menores_ug	0.88
num_desocupados_ug	tasa_desempleo_ug	0.87
num_cotizantes	prop_cotizantes_ocupados_ug	0.84
num_inactivos	prop_inactividad	0.82
num_edad_jefe	num_edad_promedio_ug	0.78
num_edad_trabajar	num_personas_hogar	0.76
num_personas_ug	num_edad_trabajar	0.76

Relaciones que se cumplen por construcción

El error máximo es la mayor diferencia absoluta en train. Cero, o ruido de redondeo, quiere decir que la igualdad se cumple.

Relación	Error máximo
personas por cuarto = personas del hogar / cuartos	0.0e+00
proporción de ocupados = ocupados / personas de la UG	0.0e+00
inactividad = inactivos / personas de 18 a 65, si las hay	0.0e+00
dependencia = (menores + mayores) / personas de 18 a 65, si las hay	0.0e+00
desempleo = desocupados / activos, si los hay	0.0e+00

Qué sostiene el análisis, y qué no

La muestra de entrenamiento tiene 164,960 hogares, sin faltantes después de las reglas de limpieza.
La clase pobre es el 20.02%. El acierto del clasificador ingenuo es 79.98% y su F1 es 0.

Las cinco variables numéricas que más separan pobres de no pobres:
• num_cotizantes: SMD -0.92, más baja en pobres.
• num_minors: SMD +0.85, más alta en pobres.
• prop_menores_ug: SMD +0.84, más alta en pobres.
• prop_cotizantes_ocupados_ug: SMD -0.84, más baja en pobres.
• prop_ocupados: SMD -0.82, más baja en pobres.

Ninguna variable numérica pasa de 0,1 en la diferencia estandarizada entre train y test.
El desajuste grueso de composición es Bogotá: 10,567 hogares en train y ninguno en test.

Varias columnas son transformaciones de otras (personas por cuarto, proporción de ocupados, tasas de dependencia, inactividad y desempleo).
El bosque puede usarlas juntas. No hay que leerlas como 43 causas distintas de la pobreza.

Este informe describe la muestra. No dice que una variable cause la pobreza, ni cómo le irá al modelo en el tablero de Kaggle:
el test no trae la clase verdadera.