LightGBM: el modelo ganador

Best Model Overview

F1 público en Kaggle

0,77

F1 en CV: **0,768**

Modelo	LightGBM (GBDT)
Predictores	1.296 variables, X7
Hojas / rondas	31 / 748
Aprendizaje	0,04
Validación	5 folds estratificados
Umbral	0,394

Tres hallazgos para leer el resultado

- Vivienda y mercado laboral concentran la señal predictiva.
- Las relaciones observadas contienen curvaturas y umbrales.
- Aún queda fuera el **20,6 %** de los hogares pobres.

Equipo 03. Fuentes: registro de modelos, puntajes públicos de Kaggle y artifact de importancia.

1.296 predictores: cómo interpretarlos

Agregamos información del hogar y de sus miembros en **1.296 variables derivadas**.

El costo de esa riqueza

- Medidas redundantes.
- Interacciones difíciles de leer.
- Menor interpretación directa.

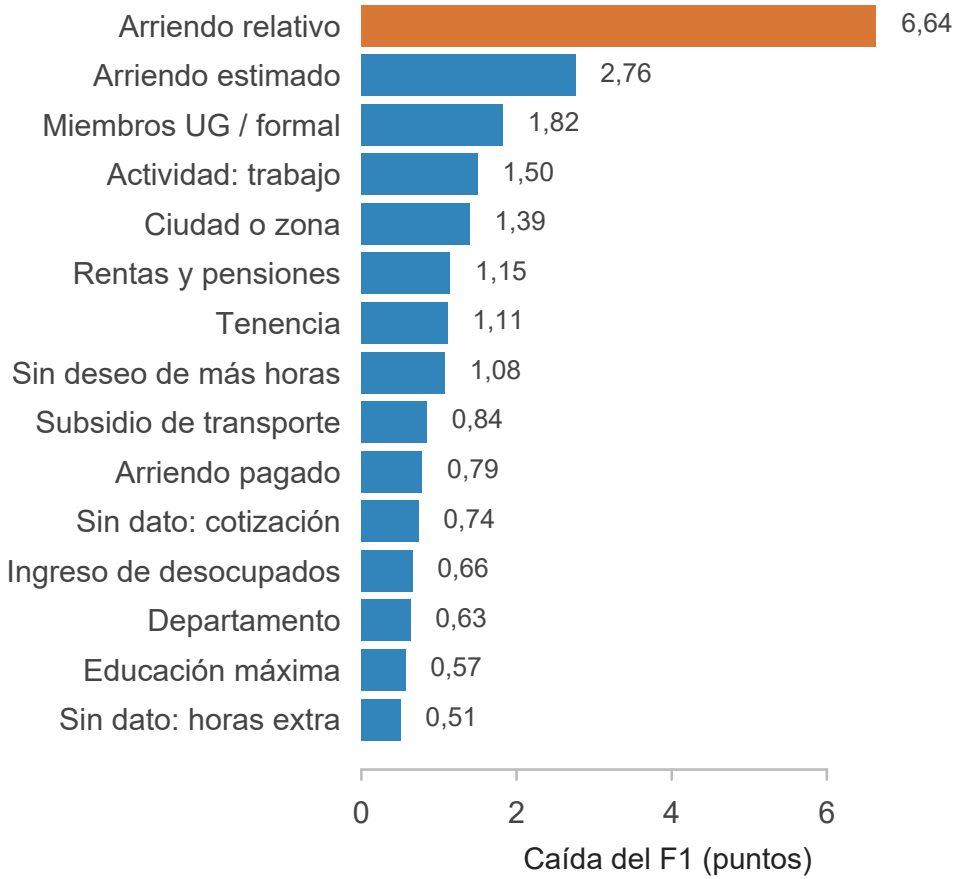
Una ruta para entenderla

1. **Permutar:** cuánto cae el F1.
2. **Describir:** cómo cambia la pobreza.
3. **Contrastar:** balance entre muestras.

Podemos interpretar la predicción sin atribuirle efectos causales.

Construcción de X7 y análisis descriptivo del proyecto. Una variable derivada no equivale a una pregunta de encuesta.

Qué variables aportan más señal



Lectura económica

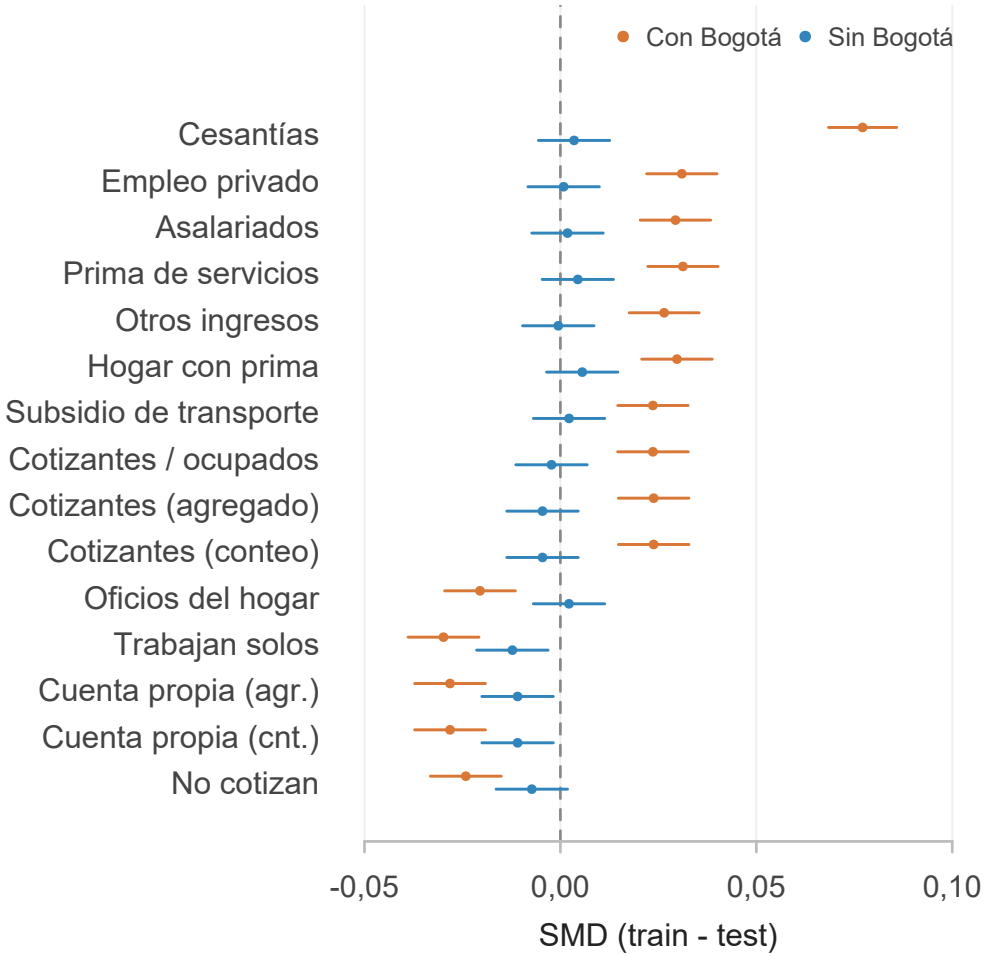
- **Vivienda:** recursos y valor locativo.
- **Formalidad:** estabilidad y protección.
- **Composición:** ingresos que se reparten.

Más caída del F1 implica mayor dependencia predictiva.

Permutación: promedio de 3 repeticiones, 5 folds y unos 2.000 hogares de validación por fold. Caídas en puntos de F1; no son efectos causales ni contribuciones aditivas.

La señal de pobreza se concentra en la vivienda y en la capacidad laboral del hogar.

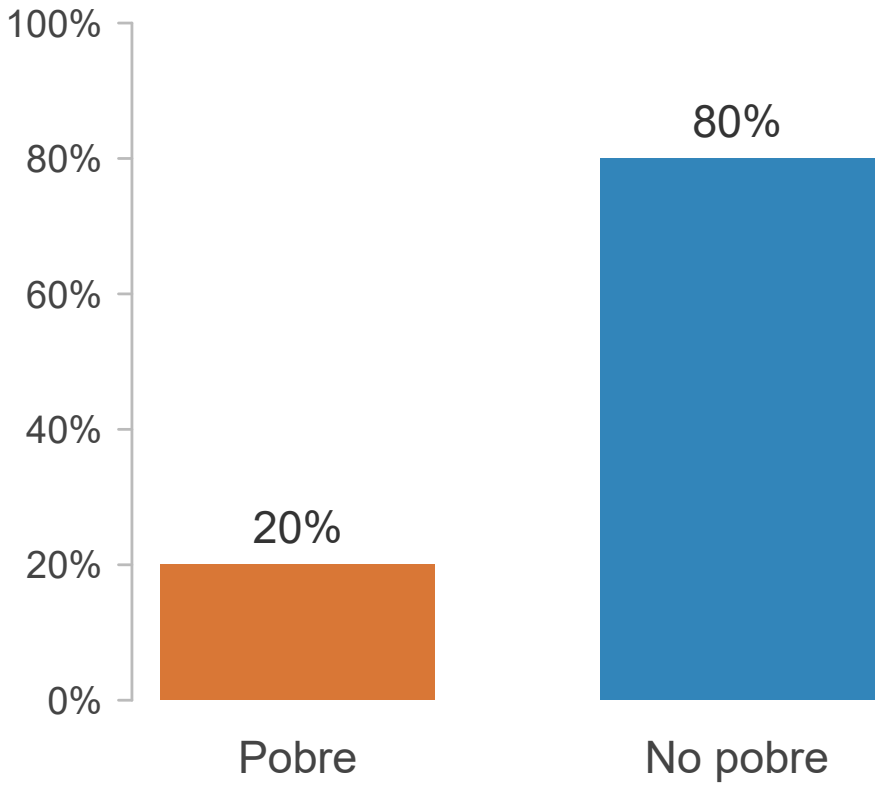
Bogotá y las diferencias entre muestras



- Bogotá pesa **6,4 %** en train y no aparece en test.
- Empleo formal y prestaciones muestran los mayores cambios.
- Excluirla acerca varias medias; no garantiza mejor predicción.

Comparación original del script 04: 15 variables con mayor cambio en el valor absoluto del SMD al excluir Bogotá. Diferencia estandarizada train – test e IC del 95 %.

El desbalance y un clasificador ingenuo



Train: 164.960 hogares

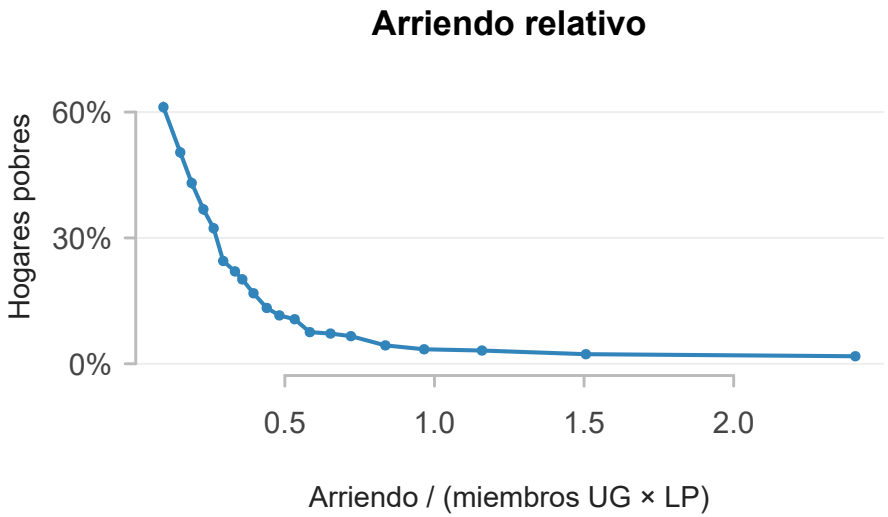
Clasificar a todos como no pobres

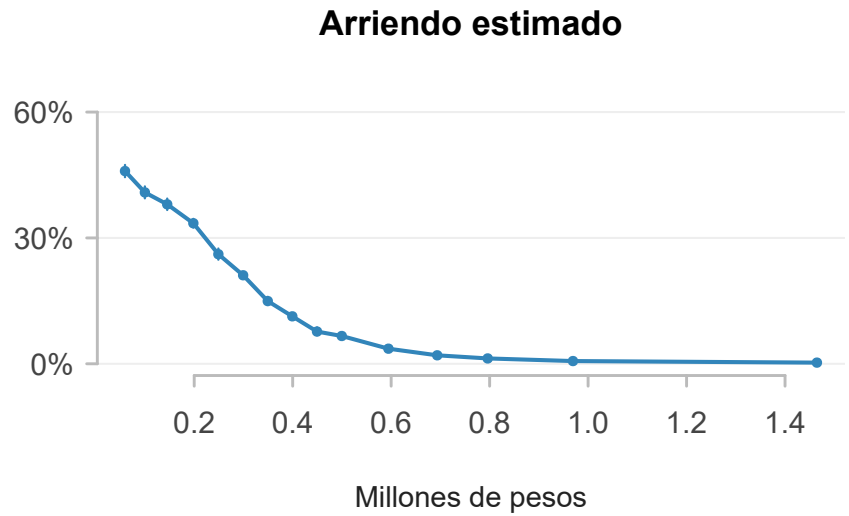
Exactitud	79,98 %
F1	**0,00**
Sensibilidad	0 %
Especificidad	100 %

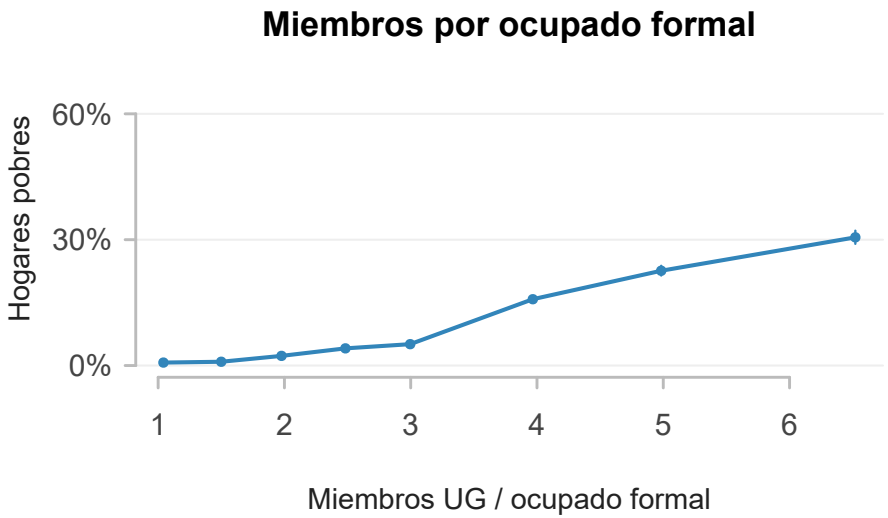
No identificaríamos a ningún hogar pobre.

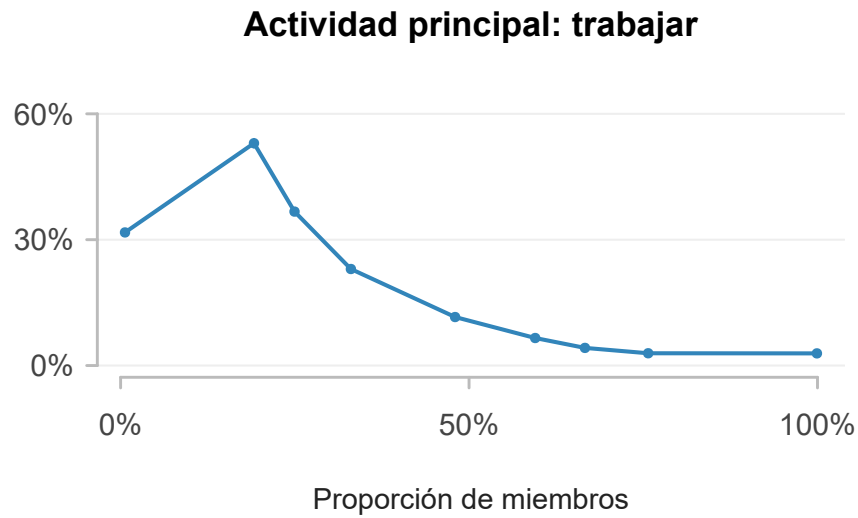
Distribución de Pobre en train. Clase positiva: hogar pobre. Métricas de asignar a todos a No pobre, sin entrenar un modelo.

Forma funcional de los principales predictores









Las curvaturas y los umbrales observados motivan una especificación flexible.

Cuatro primeros del ranking. Tasas por grupos de cuantiles, IC de Wilson del 95 %, casos válidos y rango P1–P99. UG: unidad de gasto; LP: línea de pobreza.

Por qué LightGBM se ajusta a estos patrones

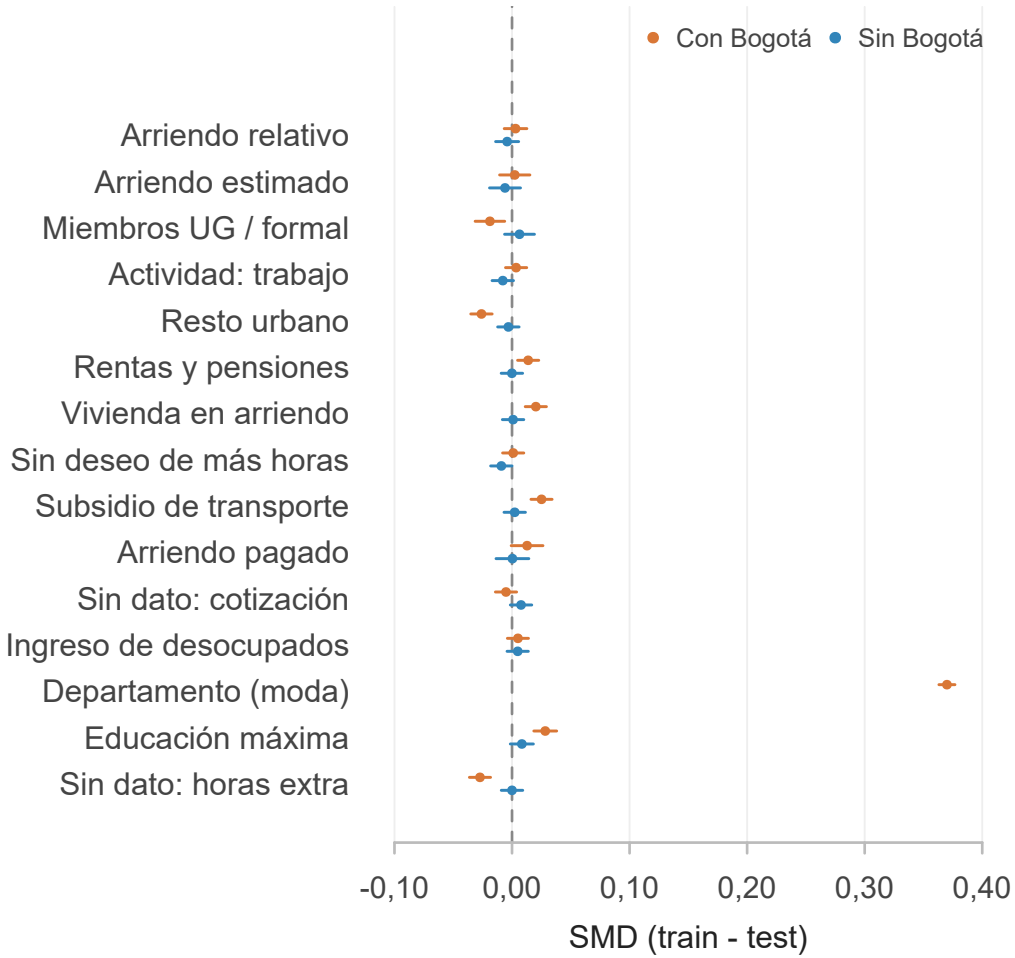
Desafío	**Configuración seleccionada**
Curvaturas e interacciones	Árboles: 31 hojas y 748 rondas
Muchas variables y sobreajuste	100 casos por hoja; L1/L2 = 0,1/10
Control del aprendizaje	Tasa 0,04; 85 % de filas y variables
Clase pobre minoritaria	Umbral 0,394 elegido por F1 OOF

Con X7 y cinco folds: **LightGBM 0,768** frente a **XGBoost 0,762**.

La flexibilidad motiva el modelo; el F1 de validación respalda su selección.

Configuración y resultados del script 11. Se documenta búsqueda de 100 umbrales; no se conserva una bitácora de búsqueda de hiperparámetros de LightGBM.

El ganador sí se entrenó con Bogotá



- Se conservaron los **10.567 hogares** de Bogotá.
- La mayoría de variables clave tiene brechas pequeñas.
- Departamento conserva una diferencia territorial.

15 principales del LightGBM; SMD train – test e IC del 95 %. Categóricas: indicador modal. El SMD de departamento sin Bogotá no se define por varianza nula.

Diagnóstico del modelo ganador

Realidad

Predicción	Pobre	No pobre
Pobre	**26.236**	9.027
No pobre	6.788	**122.909**

Umbral 0,394; predicciones OOF.

Precisión	74,4 %
Sensibilidad	79,4 %
F1	**0,768**
AUC ROC	0,957

La mejora predictiva convive con 6.788 hogares pobres que quedan fuera.

Registro de modelos. Conteos enteros reconstruidos de precisión y sensibilidad OOF y del total por clase; reproducen el F1 registrado.

Filtración y subcobertura

Filtración

25,6 %

de los seleccionados no son pobres

Subcobertura

20,6 %

de los pobres quedan fuera

9.027 falsos positivos: recursos que llegan a hogares no pobres.

6.788 falsos negativos: hogares pobres excluidos del beneficio.

Bajar el umbral amplía cobertura y puede aumentar la filtración; subirlo restringe el acceso.

Diagnóstico OOF: filtración = FP/(TP+FP); subcobertura = FN/(TP+FN). Los denominadores representan poblaciones distintas.

Condiciones para una política real

Pregunta	**Condición antes de desplegar**
¿Encuesta corta?	Recoger vivienda, composición y trabajo de los miembros; validar una versión reducida.
¿Datos disponibles a tiempo?	Revisar ayudas y afiliación subsidiada: posible circularidad con la focalización vigente.
¿Funciona fuera de la muestra?	Validar por territorio y período; definir umbral según presupuesto y costo de excluir.

Es un candidato para apoyar la focalización, sujeto a validación operativa y territorial.

Diseño de X7 y diagnósticos del proyecto. El desempeño de una encuesta reducida aún no se ha validado.