Predicción de pobreza en Colombia

Best Model Deep Dive

Andrés Silva, Valentina Vera & Julián Herrera

Universidad de los Andes

MECA 4107, 2026-20

Contenido

1. Descripción del modelo ganador
2. Caracterización del problema
    - ¿Qué datos tenemos?
    - Retos para la predicción.
3. Construcción del modelo
    - Proceso de elección.
    - Resultados
    - ¿Por qué funcionó?.
4. **Variable importance**
5. Implicaciones de política pública

El modelo ganador

F1 público en Kaggle

0,77

F1 en CV: **0,768**

Especificación del modelo

- **Predictores:** 1.296 variables
- **Complejidad:** 31 hojas y 748 rondas
- **Learning rate:** 0,04
- **Validación:** 5 folds estratificados
- **Umbral óptimo:** 0,394

Equipo 03. Fuentes: registro de modelos y puntajes públicos de Kaggle.

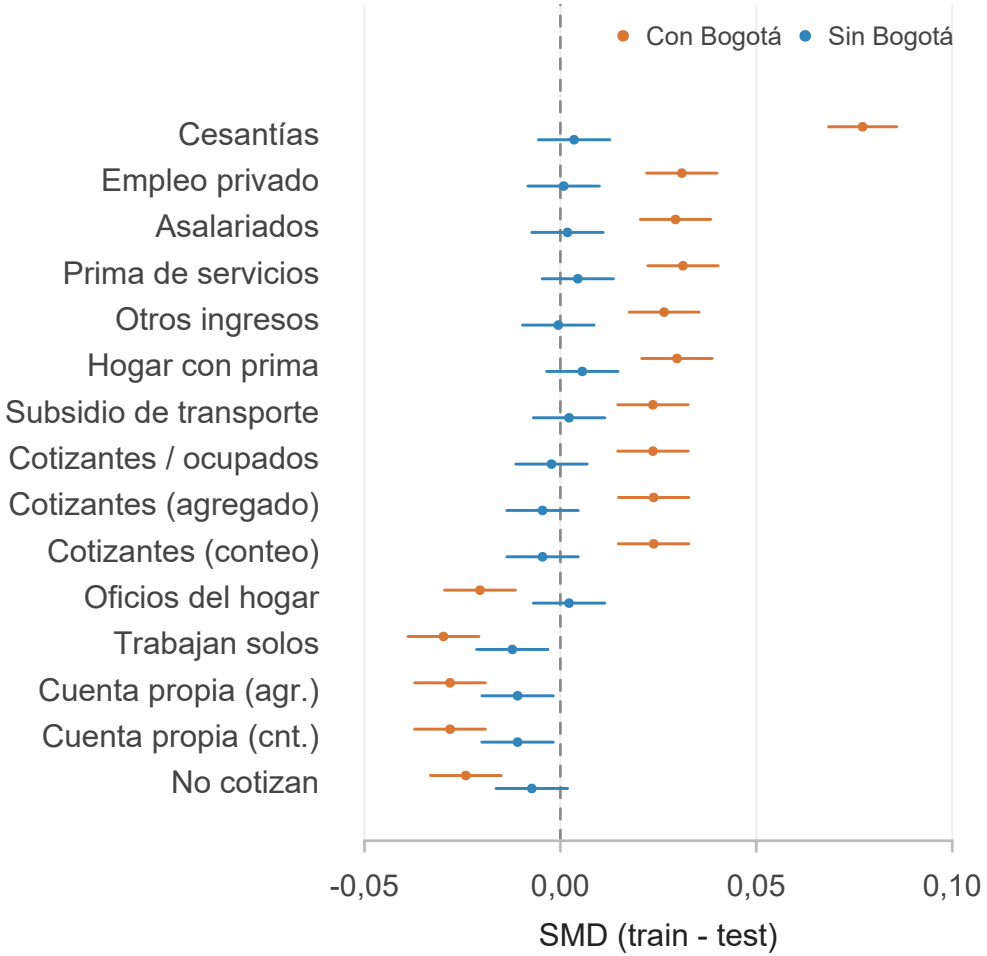
Caracterización del problema

Datos, desbalance y ausencia de Bogotá en test

¿Qué datos tenemos?

- 4 bases de datos. una para hogar, otra de personas para entrenamiento y para evaluación
- 231.128 hogares.
  - Train: 164.960 hogares.
  - Test: 66.168 hogares.
- Train incluye Bogotá, mientras que test no.
- Predictores disponibles
  - Train: 148.
  - Test: 79.

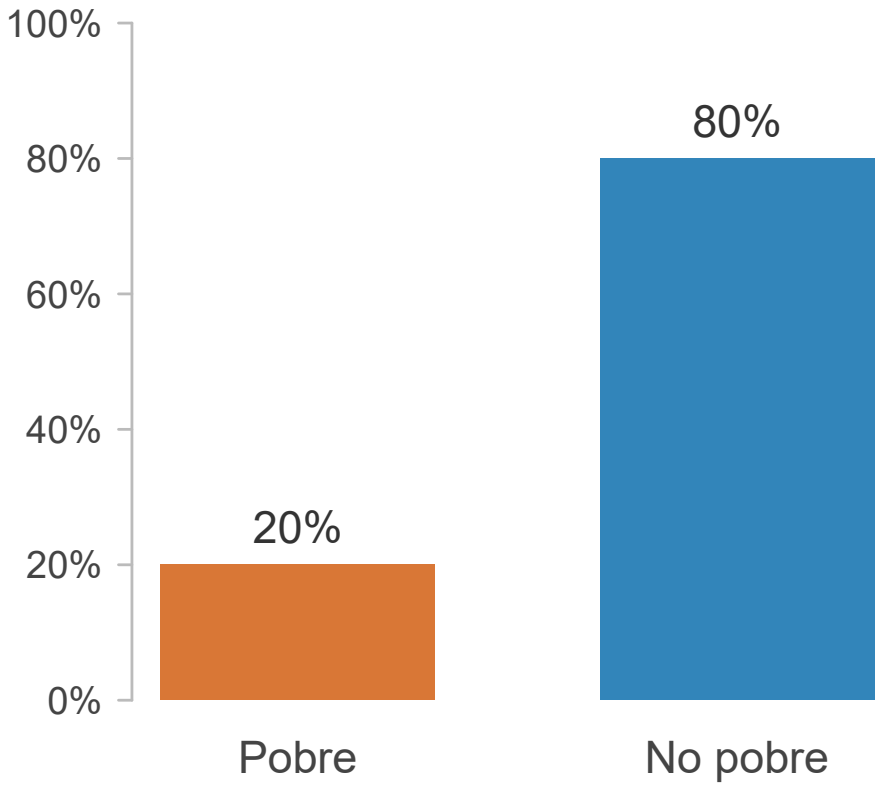
Caracterización: Bogotá



- Bogotá compone el **6,4 %** del conjunto de entrenamiento y no aparece en el de testeo.
- Ninguna variable muestra una diferencia importante respecto al test, aunque son estadísticamente existentes.
- Excluirla acerca varias medias; no garantiza mejor predicción (se verá más adelante).

Comparación original del script 04: 15 variables con mayor cambio en el valor absoluto del SMD al excluir Bogotá. Diferencia estandarizada train – test e IC del 95 %.

Caracterización: desbalance



Train: 164.960 hogares

Clasificador ingenuo: nadie es pobre

Accuracy	79,98 %
F1	**0,00**
Sensibilidad	0 %
Especificidad	100 %

No se identifican pobres pero se consigue accuracy del 80 % aprox.

Distribución de Pobre en train. Clase positiva: hogar pobre. Métricas de asignar a todos a No pobre, sin entrenar un modelo.

Elección del modelo

Entrenamiento, validación y optimización

Cómo se describe cada hogar

Dimensiones económicas

- **Vivienda:** arriendo pagado o estimado, tenencia y hacinamiento.
- **Trabajo y protección:** ocupación, formalidad aproximada, cotización, salud y prestaciones.
- **Capital humano y composición:** educación, edades, menores y adultos mayores.
- **Otros recursos:** presencia de pensiones, rentas y transferencias.
- **Territorio:** ciudad, zona y

Formas de representar esa información

- **Composición:** cuántos miembros trabajan o cotizan y qué proporción del hogar representan.
- **Distribución interna:** promedios, máximos, mínimos, dispersión y sumas. Por ejemplo, educación máxima de los ocupados.
- **Recursos frente a necesidades:** personas por cuarto, miembros por ocupado formal y arriendo ajustado por tamaño del hogar.
- **Perfiles individuales:** características del jefe, cónyuge y tres miembros de mayor edad.

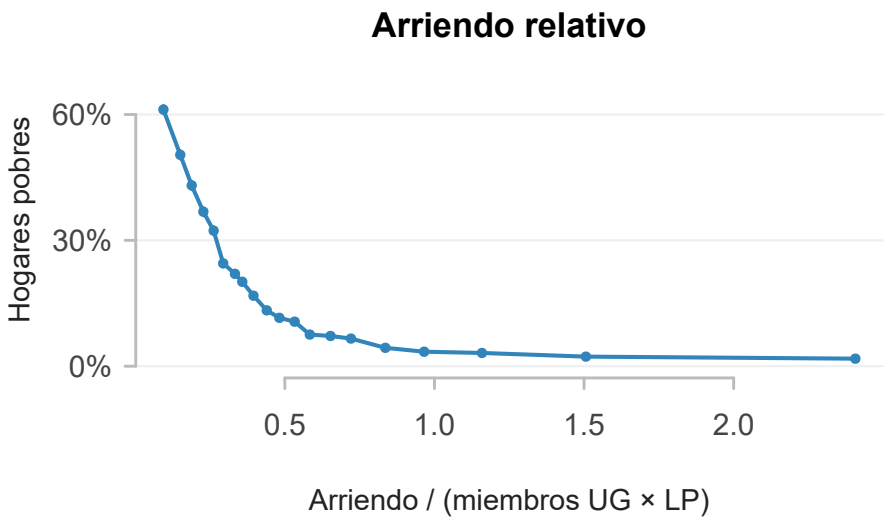
Elección del modelo e hiperparámetros

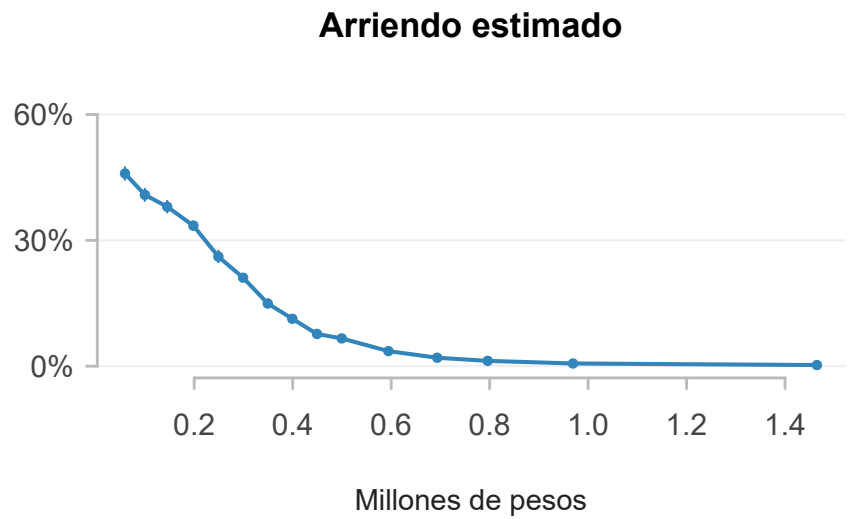
Desafío	**LightGBM**
Modelo	Tras probar varios modelos tuneados, este obtuvo el mayor F1
Umbral	Búsqueda exhaustiva del umbral
Hiperparámetros	Se probaron distintas configuraciones y se hizo busqueda cerca a las mejores.
Estrategia de validación	4-fold validation para entrenamiento (con Bogotá) + hold-out sin Bogotá

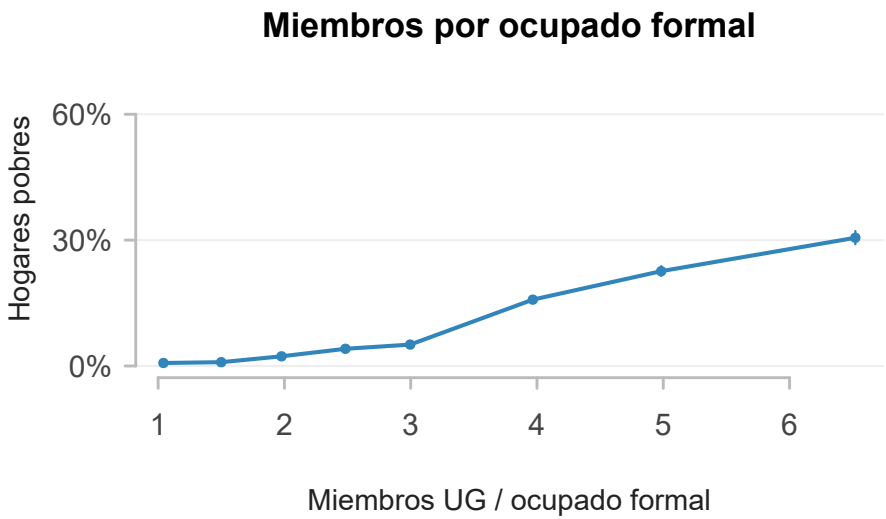
La buena elección de predictores y el umbral fueron determinantes.

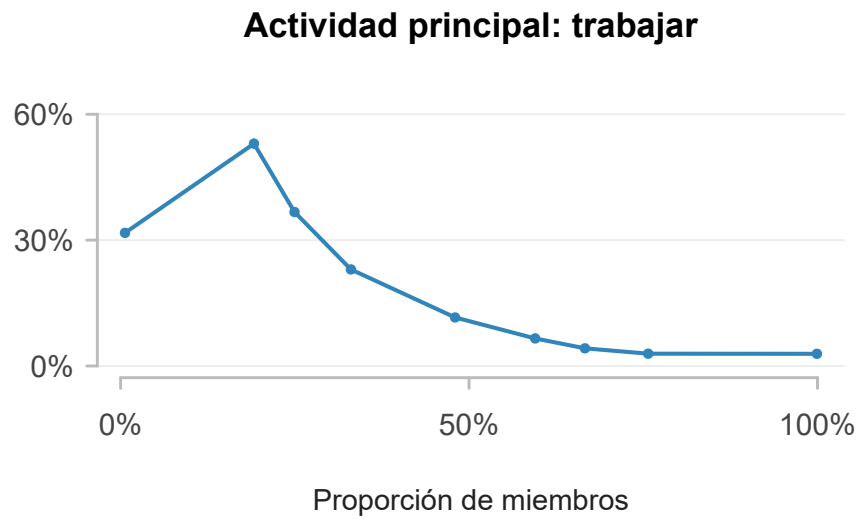
Configuración y resultados del script 11. Se documenta búsqueda de 100 umbrales; no se conserva una bitácora de búsqueda de hiperparámetros de LightGBM.

¿Por esta configuración con LGBM fue la de mejor desempeño?



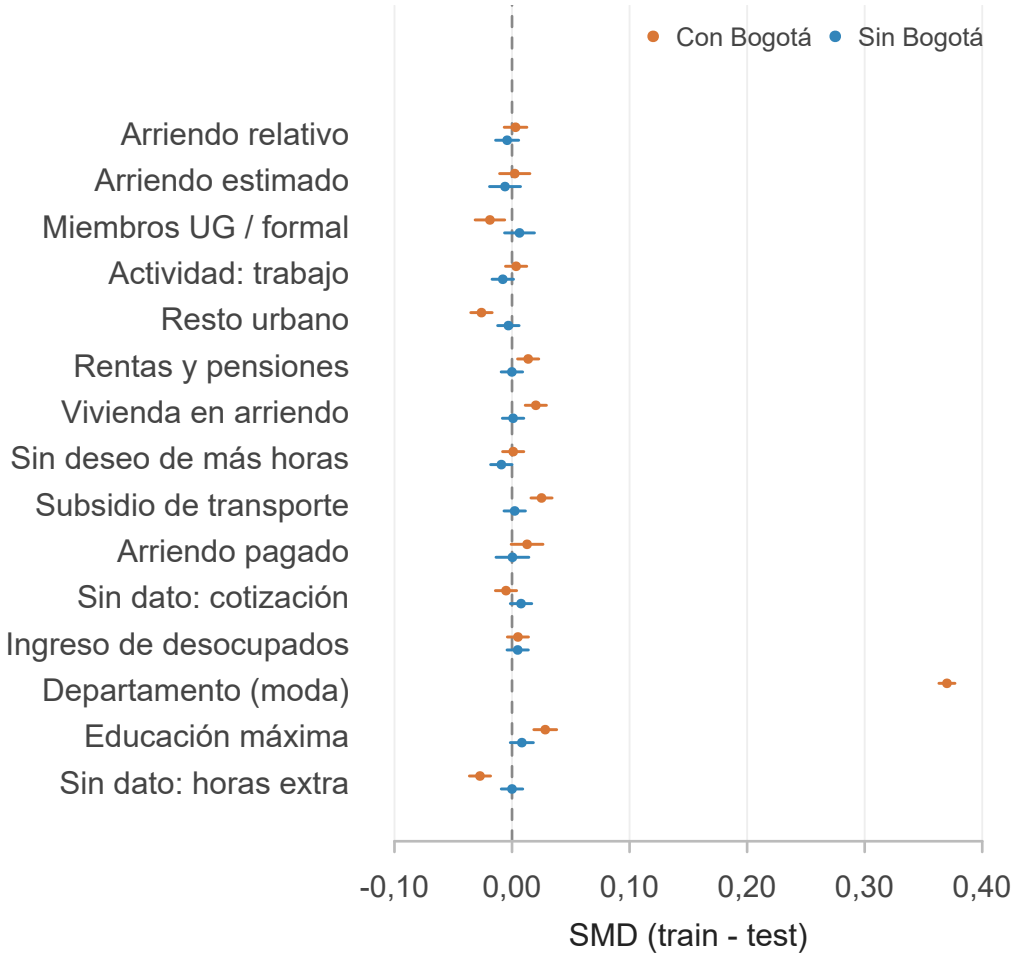






La capacidad de LGBM de ajustar formas funcionales complicada es clave en este

¿Por esta configuración con LGBM fue la de mejor desempeño?



- Se conservaron los **10.567 hogares** de Bogotá.
- La mayoría de variables clave tiene brechas pequeñas (VI se ahondará más adelante).
- Bogotá no fue un problema. El mejor modelo mantuvo a Bogotá en su entrenamiento.

15 principales del LightGBM; SMD train – test e IC del 95 %. Categóricas: indicador modal. El SMD de departamento sin Bogotá no se define por varianza nula.

¿Por esta configuración con LGBM fue la de mejor desempeño?

- LGBM ajusta muy bien a formas complejas.
- La búsqueda del umbral óptimo permitió abordar el desbalance.
- Bogotá no añadía diferencias sustanciales, lo que peritió aprovecharlo.

Variable importance e interpretabilidad

Importancia por permutación, matriz de confusión y relación con public policy

El reto de la interpretabilidad

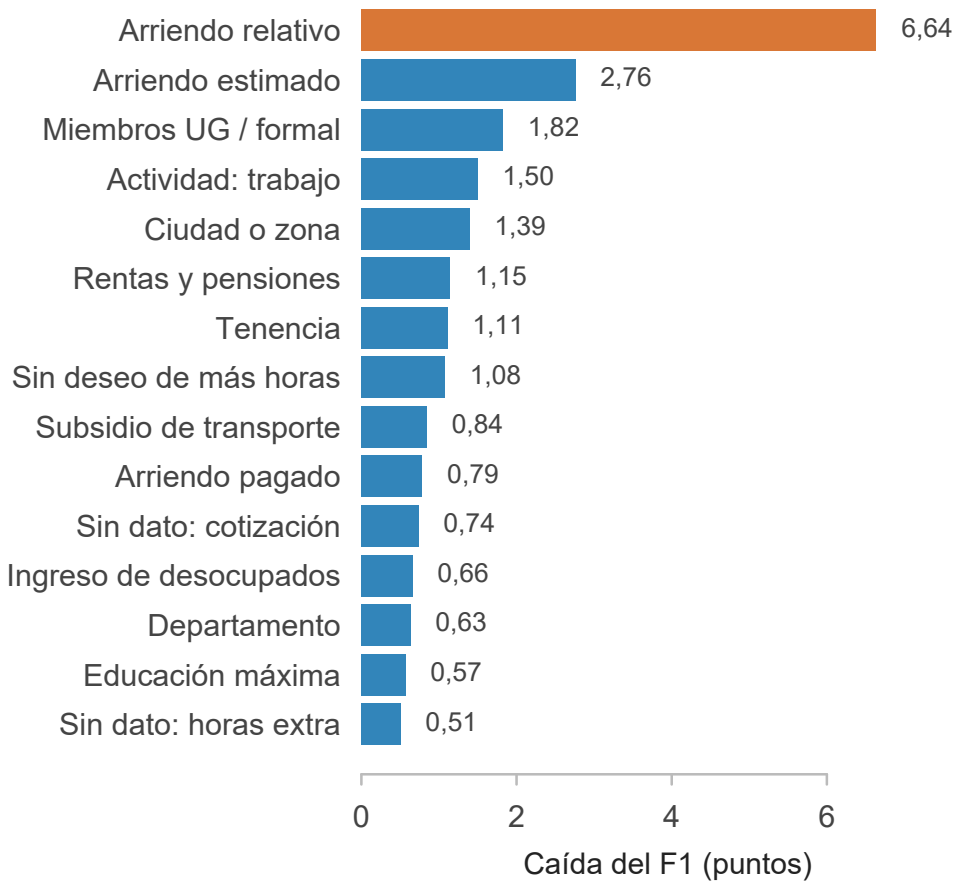
Un LGBM con 1296 predictores es poco o nada interpretable por si sólo. Se puede abordar este problema

- Importancia por permutación.
- Relacion con public policy y análisis socioeconómico.

Podemos interpretar la predicción sin atribuirle efectos causales.

Construcción de X7 y análisis descriptivo del proyecto. Una variable derivada no equivale a una pregunta de encuesta.

Variables con más poder predictivo



Componentes clave

- **Arriendo relativo:** arriendo normalizado por costo de vida
- **Tipo de trabajo** formal, tipo de actividad.
- **Composición:** fuentes y tipos de ingresos (rentas, pensiones, subsidios).

Mayor caída del F1 tras permutación implica mayor poder predictivo.

Permutación: promedio de 3 repeticiones, 5 folds y unos 2.000 hogares de validación por fold. Caídas en puntos de F1; no son efectos causales ni contribuciones aditivas.

Arriendo, tipo de ocupación y fuentes de ingresos componen gran parte de la predicción.

Desempeño de la clasificación

Matriz de confusión y medidas de desempeño

Implicación de política pública

Predicción/Real	Pobre	No pobre
Pobre	**26.236**	9.027
No pobre	6.788	**122.909**

Umbral 0,394; predicciones OOF.

Precisión	74,4 %
Sensibilidad	79,4 %
F1	**0,768**
AUC ROC	0,957
Accuracy	0,90

La mejora predictiva convive con 6.788 hogares pobres que quedan fuera.

Registro de modelos. Conteos enteros reconstruidos de precisión y sensibilidad OOF y del total por clase; reproducen el F1 registrado.

Public policy

Matriz de confusión y variable importance para public policy

Implicaciones de política pública

Filtración

25,6 %

de los seleccionados no son pobres

Subcobertura

20,6 %

de los pobres quedan fuera

9.027 falsos positivos: recursos que llegan a hogares no pobres.

6.788 falsos negativos: hogares pobres excluidos del beneficio.

Bajar el umbral amplía cobertura y puede aumentar la filtración; subirlo restringe el acceso.

Diagnóstico OOF: filtración = FP/(TP+FP); subcobertura = FN/(TP+FN). Los denominadores representan poblaciones distintas.

Condiciones para una política real

Pregunta	Condición antes de desplegar
FALTA LA RELACIÓN CON PUBLIC POLICY	

Es un candidato para apoyar la focalización, sujeto a validación operativa y territorial.

Diseño de X7 y diagnósticos del proyecto. El desempeño de una encuesta reducida aún no se ha validado.