Universidad de los Andes

Guía de modelos y resultados

Predicción de pobreza en Colombia

Problem Set 2 · MECA 4107
Big Data y Machine Learning para Economía Aplicada

Equipo 03
Julián Herrera Andrés Silva Valentina Vera

Corte del 26 de octubre de 2026, antes de nuevos cambios.
Métrica de la competencia: F1 del hogar pobre.

Cómo leer esta guía

Dos puntajes, no uno.

- **F1 en CV.** Validación cruzada de 5 folds. El umbral maximiza ese F1 fuera de muestra.
- **Puntaje público.** El de Kaggle. Solo existe si el envío está en `kaggle_scores.csv`.

Un CSV en `predictions/` sin fila en el registro no es un resultado.

Qué se puede comparar.

- Algoritmos entre sí: solo el mismo conjunto, **X5** (43 predictores).
- Conjuntos entre sí: la escalera del logit o la de CART, un algoritmo a la vez.
- X6 y X7 mezclan más variables con el algoritmo.

Línea de base para los cambios que vienen

Hoy el mejor es LightGBM con X7: F1 en CV de 0.768 y puntaje público de 0.77. Un modelo nuevo se compara contra ese par y contra el mejor del mismo conjunto.

Conjuntos de predictores

Los conjuntos están anidados: cada uno contiene al anterior y agrega un bloque. X7 no amplía X6: vive en otras bases y tiene faltantes.

Conjunto	Pred.	Qué agrega
X1 vivienda	5	Ubicación, tenencia, hacinamiento, personas y menores.
X2 demografía	11	Jefe, adultos mayores, edad de trabajar, dependencia y educación.
X3 empleo	15	Ocupados e inactivos, en número y en proporción.
X4 completo	21	Cotización, pensión, horas, asalariados, cuenta propia y oficio del jefe.
X5 extendido	43	Arriendo, edades, desempleo, salud, subempleo y transferencias. Es el conjunto común.
X6 detallado	148	X5 más los conteos de personas por categoría.
X7 ampliado	1 296	Hogar y miembros en detalle. Solo LightGBM y XGBoost: tiene faltantes.

Baseline: clasificar a todos como no pobres

Métrica	Resultado
Accuracy	79.98 %
F1	0.00
Sensibilidad	0.00
Especificidad	100 %

Cerca de 80 % de los hogares de entrenamiento no son pobres. Un clasificador que nunca dice “pobre” acierta la mayoría y falla la métrica de la competencia.

Para el slide

El accuracy no se presenta como desempeño. El punto de partida de todos los modelos es un F1 de cero.

Logit: la escalera de información

Misma regresión logística. Cambia solo el conjunto. El umbral maximiza el F1 en CV. Estos cinco envíos sí tienen puntaje público.

Conjunto	Pred.	Umbral	F1 CV	AUC	Público
X1 vivienda	5	0.25	0.521	0.793	0.53
X2 demografía	11	0.26	0.557	0.829	0.56
X3 empleo	15	0.29	0.605	0.864	0.61
X4 completo	21	0.33	0.680	0.918	0.68
X5 extendido	43	0.33	0.711	0.932	0.71

- El salto grande está entre empleo y el conjunto completo (0.61 a 0.68): formalidad, horas y oficio del jefe.
- De X4 a X5 se ganan tres puntos públicos (0.68 a 0.71) con arriendo, desempleo y transferencias.
- El F1 en CV y el puntaje público se mueven juntos. La validación está ordenando bien estos envíos.

CART: la misma escalera, y el rebalanceo

Árbol de clasificación con el `cp` elegido en una grilla. La escalera no se envió a Kaggle, salvo las dos variantes de X5.

Variante	Rebalanceo	Umbral	F1 CV	Recall	Público
X1 vivienda	sin	0.24	0.514	0.571	—
X2 demografía	sin	0.22	0.544	0.635	—
X3 empleo	sin	0.24	0.590	0.651	—
X4 completo	sin	0.26	0.658	0.716	—
X5 extendido	sin	0.28	0.686	0.714	0.67
X5 extendido	up	0.75	0.685	0.794	0.68
X5 extendido	down	0.74	0.677	0.792	—

El orden de la escalera es el mismo del logit, unos tres puntos de F1 por debajo. Igualar las clases mueve el umbral de 0.28 a 0.75 y sube el recall, pero el F1 en CV no mejora. En Kaggle, el upsampling queda en 0.68, un punto sobre el árbol sin rebalanceo.

Comparación justa: todos sobre X5

43 predictores, sin rebalanceo, ordenados por F1 en CV. El guion indica que no hay puntaje público.

Algoritmo	Umbral	F1 CV	Precisión	Recall	AUC	Público
LightGBM	0.31	0.731	0.659	0.820	0.942	—
XGBoost	0.37	0.729	0.686	0.778	0.941	—
Random forest, mtry 31	0.34	0.715	0.651	0.792	0.933	—
AdaBoost	0.46	0.712	0.664	0.768	0.933	—
Elastic net	0.35	0.711	0.670	0.758	0.932	—
Logit	0.33	0.711	0.660	0.771	0.932	0.71
Random forest, mtry 6	0.36	0.704	0.656	0.759	0.928	—
LPM	0.36	0.688	0.633	0.753	0.922	—
CART	0.28	0.686	0.660	0.714	0.899	0.67
Naive Bayes	0.88	0.644	0.585	0.717	0.892	—

LightGBM: 31 hojas, 748 rondas. XGBoost: profundidad 5, 314 rondas. AdaBoost: 100 iter., profundidad 5. Elastic net: $\alpha = 0.25$.

Rebalanceo sobre X5: el umbral cambia, el F1 casi no

Se replican hogares pobres en el entrenamiento (hasta cuatro veces, o hasta igualar clases en CART). El test y la validación conservan la proporción real.

Algoritmo	Tratamiento	Umbral	F1 CV	Recall	Contra el original
CART	up	0.75	0.685	0.794	-0.001
CART	down	0.74	0.677	0.792	-0.009
AdaBoost	pobres $\times 4$	0.55	0.714	0.790	$+0.002$
Random forest, mtry 31	pobres $\times 4$	0.52	0.710	0.765	-0.004
Naive Bayes	pobres $\times 4$	0.96	0.644	0.724	0.000

Para el slide

El desbalance se corrige mejor moviendo el umbral que replicando hogares. El único público que mejora con rebalanceo es CART: de 0.67 a 0.68.

Modelos lineales, en una ficha

Modelo	Especificación registrada	F1 CV	AUC	Público
LPM 10	Diez predictores de vivienda, demografía y empleo. Umbral 0.33.	0.625	0.883	—
LPM X5	Los 43 predictores. Umbral 0.36.	0.688	0.922	—
Logit X5	Sin penalización. Umbral 0.33.	0.711	0.932	0.71
Elastic net	Logit penalizado, $\alpha = 0.25$, $\lambda = 10^{-4}$. Umbral 0.35.	0.711	0.932	—

- Con las mismas 43 variables, la penalización no mejora el F1 del logit: los dos quedan en 0.711.
- El LPM corto (10 variables) queda en 0.625, entre el logit de empleo y el logit completo.
- Hay más CSV de elastic net (Bogotá, otros α, X6) y dos LPM (`LPM_41`, `LPM_X6`) sin fila en el registro. No entran en esta guía como resultado.

Boosting: el salto está en las variables

Misma receta dentro de cada algoritmo. Cambia el conjunto.

Modelo	Conjunto	Umbral	F1 CV	AUC	Público
XGBoost	X5, 43	0.37	0.729	0.941	—
XGBoost	X6, 148	0.37	0.757	0.952	0.76
XGBoost	X7, 1 296	0.39	0.762	0.954	0.76
LightGBM	X5, 43	0.31	0.731	0.942	—
LightGBM	X7, 1 296	0.39	0.768	0.957	0.77

- XGBoost: de X5 a X6 gana 0.028 de F1 en CV. De X6 a X7 solo gana 0.005, y en Kaggle los dos quedan en 0.76.
- LightGBM en X5 ya empata al mejor XGBoost de X5 (0.731 contra 0.729). Con X7 llega a 0.768 y al público de 0.77.
- XGBoost: profundidad 5, $\eta = 0.10$, peso mínimo de hijo 5. LightGBM: 31 hojas, tasa 0.04, $\lambda_2 = 10$, $\lambda_1 = 0.1$, 748 rondas.

Puntajes públicos, de mayor a menor

Solo envíos anotados. El LightGBM de X7 reemplazó un envío anterior con el mismo público de 0.77; se cita el archivo vigente.

Público	Fecha	Envío
0.77	25 oct.	LightGBM, X7, 31 hojas, 748 rondas, umbral 0.39.
0.76	22 oct.	XGBoost, X6, profundidad 5, 516 rondas, umbral 0.37.
0.76	25 oct.	XGBoost, X7, profundidad 5, 388 rondas, umbral 0.39.
0.71	20 oct.	Logit, X5, umbral 0.33.
0.68	20 oct.	CART, X5, upsampling, umbral 0.75.
0.68	17 oct.	Logit, X4 completo, umbral 0.33.
0.67	20 oct.	CART, X5, sin rebalanceo, umbral 0.28.
0.61	17 oct.	Logit, X3 empleo, umbral 0.29.
0.56	17 oct.	Logit, X2 demografía, umbral 0.26.
0.53	17 oct.	Logit, X1 vivienda, umbral 0.25.

El mejor modelo, en una diapositiva

LightGBM · X7 ampliado

Dato	Valor
F1 en CV	0.768
Precisión	0.744
Recall	0.794
AUC	0.957
Umbral	0.39
Puntaje público	0.77

Qué decir, y qué no.

- Es el mejor F1 en CV y el mejor público.
- Parte de esa ventaja es el conjunto: 1 296 variables, no solo el algoritmo.
- En X5, LightGBM (0.731) y XGBoost (0.729) están empatados, ocho puntos por encima del logit (0.711).
- El segundo público es 0.76, compartido por XGBoost en X6 y en X7.

Qué distingue a un hogar pobre

Importancia en X5, escalada de 0 a 100 dentro de cada modelo. Las dos listas coinciden en el núcleo: arriendo, empleo y formalidad.

Random forest

Variable	0–100
Proporción de ocupados	100
Arriendo por persona (log)	98
Horas trabajadas	76
Hogar pensionado	47
Cotizantes entre ocupados	37

AdaBoost

Variable	0–100
Arriendo por persona (log)	100
Proporción de ocupados	69
Cotizantes entre ocupados	65
Hogar pensionado	52
Número de cotizantes	45

Estas importancias son de los modelos en X5, no del LightGBM de X7. Sirven para el slide de mecanismos. No se usan como ranking del modelo ganador.

Archivos que no entran como resultado

Están en `02_outputs/predictions/` y no tienen fila en `registro_modelos.csv`, o no tienen puntaje público. No se citan en los slides hasta registrar el F1.

- **Elastic net,** varias pruebas: con y sin Bogotá, α de 0.25, 0.5 y 1, X6 y un envío con pesos. En el registro solo está $\alpha = 0.25$, $\lambda = 10^{-4}$, F1 0.711, sin público.
- **LPM:** `LPM_41.csv` y `LPM_X6_detallado.csv`. Registrados solo `LPM_10` (0.625) y `LPM_X_5` (0.688), sin público.
- **XGBoost:** la búsqueda de 250 configuraciones y la variante de 352 rondas. La configuración de X5 que sí está medida es la de 314 rondas, F1 0.729, sin público.
- **Sin público, aunque el F1 en CV sí está:** LightGBM en X5, XGBoost en X5, los dos random forest, AdaBoost, Naive Bayes, elastic net, los dos LPM y CART con downsampling.

Guion para los slides, antes de cambiar modelos

1. El baseline acierta el 80 % y tiene F1 de 0. La métrica es el F1.
2. Logit en Kaggle: vivienda 0.53, demografía 0.56, empleo 0.61, completo 0.68, extendido 0.71. CART repite el orden y solo X5 está publicado.
3. En X5, de mejor a peor: boosting, bosques y AdaBoost, logit y elastic net, LPM, CART, Naive Bayes.
4. Replicar hogares pobres casi no mueve el F1. El umbral sí.
5. En Kaggle, XGBoost llega a 0.76 con X6 y con X7. LightGBM con X7 llega a 0.77.
6. Separar “mejor algoritmo en X5” de “mejor envío de la competencia”.

Antes de un modelo nuevo

Registrar F1, precisión, recall, AUC y umbral, y el público en `kaggle_scores.csv`. Si el conjunto no es X5, no entra en la tabla de algoritmos.